

重大 AI 更新提醒

09-01 | llama.cpp 新版本支持 Qwen4Exp 循环状态回滚，提升 MTP 推测解码性能

本期导读

本期聚焦 llama.cpp 最新发布 b10731，该版本为 Qwen4Exp 模型引入了循环状态回滚支持，解决了 MTP 推测解码中的上下文管理问题，显著提升了解码速度。适合使用 Qwen 系列模型进行本地推理的开发者关注。

已检查来源

GitHub Release

1. llama.cpp b10731: 支持 Qwen4Exp 循环状态回滚，提升 MTP 推测解码性能

来源 GitHub Release | 类型 GitHub Release | 主题 检索增强与向量模型 时间 09-01 00:34 | 分数 7

是什么	这是 llama.cpp 的一个新版本（b10731），主要针对 Qwen4Exp 模型增加了循环状态回滚（recurrent state rollback）的支持，以优化 MTP（Multi-Token Prediction）推测解码的效率。
通俗解释	想象你在写文章时，有时会先写几个字，然后发现不对，需要回退到之前的状态重新写。在 AI 推理中，推测解码（speculative decoding）就是让模型先快速猜几个词，然后验证，如果猜错了就要回退。对于 Qwen4Exp 这种带有循环结构的模型，回退时需要恢复之前的状态。以前这个回退操作很笨重，每次都要把整个状态复制一遍，导致速度变慢。这个更新让回退更精准，只恢复需要的部分，就像你只需要擦掉写错的几个字，而不是把整页纸都重写。
主要作用	解决 MTP 推测解码中因缺少循环状态回滚而导致的性能瓶颈，避免每次迭代都序列化整个循环状态到主机内存，从而减少开销，提升解码速度。
核心功能	支持循环状态回滚，为每个槽位写入一个快照，每个快照提前一个 token 结束，用于 delta net QKV 卷积和 PLE 卷积。；优化了上下文分类，避免使用 SEQ_RM_TYPE_FULL，减少主机内存传输。；在 Qwen3.8-Flash-Next UD-Q4_K_XL 模型上，使用独立 MTP 草稿，n-max 3 和单槽位时，解码速度达到代码 183 tok/s，散文 144 tok/s。
对比判断	根据发布说明，在相同配置下，该分支相比之前版本（未支持回滚）性能有提升，但未提供具体对比数据。
适合谁	适合使用 llama.cpp 进行本地推理的开发者，特别是使用 Qwen4Exp 或类似循环结构模型，并启用 MTP 推测解码的用户。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10731>

本简报基于 GitHub Release 信息整理，请以官方发布说明为准。