

重大 AI 更新提醒

09-01 | llama.cpp 发布 b10734，启用 Metal 4.0 张量 API

本期导读

本期聚焦 llama.cpp 最新版本 b10734，该版本针对 Apple 最新硬件（M5+/A19+）启用 Metal 4.0 张量 API，并引入外部 metallib 加载机制，为开发者带来更高效的本地推理体验。

已检查来源

GitHub Release

1. llama.cpp b10734：在 M5+/A19+ 上启用 Metal 4.0 张量 API

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 09-01 06:57 | 分数 7

是什么 这是 llama.cpp 的一个新版本（b10734），主要针对 Apple 的 Metal 图形 API 进行优化，特别是为最新的 M5 芯片和 A19 芯片启用了 Metal 4.0 张量 API。同时，该版本将张量 API 的内核代码分离到独立的 metallib 文件中，并增加了相应的回归测试。

通俗解释 想象一下，你的电脑有一个强大的图形处理器（GPU），但需要合适的驱动程序才能发挥全部性能。llama.cpp 是一个让 AI 模型在本地运行的软件，它利用 GPU 来加速计算。这次更新就像是为最新的 Apple 芯片（M5 和 A19）安装了更高效的驱动程序，让 AI 计算更快。具体来说，它使用了 Metal 4.0 的新功能，并调整了代码结构，使得加载和运行 AI 模型时更稳定、更高效。

主要作用 该版本旨在提升 llama.cpp 在 Apple 最新硬件上的推理性能，并确保与 Metal 4.0 的兼容性。对于使用 M5 或 A19 芯片的开发者，这可以显著加速本地大语言模型的运行，减少等待时间。

核心功能 启用 Metal 4.0 张量 API，针对 M5+ 和 A19+ 芯片优化；将张量 API 内核代码分离到独立的 metallib 文件，便于管理和加载；新增外部 metallib 张量 API 回归测试，确保稳定性；提供 macOS Apple Silicon、Intel 和 iOS 的预编译二进制文件

对比判断 暂无可信公开对比数据

适合谁 适合使用 Apple Silicon（特别是 M5 或 A19）的开发者，以及依赖 llama.cpp 进行本地推理的研究者和 AI 应用开发者。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10734>

本简报基于候选源生成，请以官方发布为准。