

重大 AI 更新提醒

09-06 | llama.cpp 发布 b10827，修复 OpenCL 量化权重选择

本期导读

本期聚焦 llama.cpp 最新版本 b10827，该版本针对 OpenCL 后端在矩阵乘法中的量化权重选择问题进行了修复，提升了特定量化模型在 GPU 上的推理准确性和性能。适合使用 llama.cpp 进行本地推理的开发者关注。

已检查来源

GitHub Release

1. llama.cpp b10827：修复 OpenCL 下 q4_K/q5_K 矩阵乘法的权重打包选择

来源 GitHub Release | 类型 GitHub Release | 主题 开发者生态与数据工具 | 时间 09-06 15:50 | 分数 7

是什么 这是 llama.cpp 项目的一个新版本（b10827），主要修复了 OpenCL 后端在计算 q4_K 和 q5_K 量化模型的矩阵乘法时，权重打包选择不当的问题。

通俗解释 想象一下，你在用 GPU 运行一个大型语言模型，为了节省内存，模型被压缩成一种叫 q4_K 或 q5_K 的格式。在 OpenCL（一种让 GPU 工作的通用语言）环境下，llama.cpp 之前可能选错了压缩数据的打包方式，导致计算时出错或变慢。这次更新就像给 GPU 的搬运工一本更准确的手册，告诉它如何正确打包和搬运这些压缩数据，从而让模型运行得更准确、更高效。

主要作用 解决 OpenCL 后端在特定量化模型（q4_K/q5_K）上矩阵乘法计算错误或性能下降的问题，提升推理准确性和速度，确保使用 AMD、Intel 等 GPU 的用户获得更稳定的体验。

核心功能 修复 OpenCL 后端对 q4_K 和 q5_K 量化权重的打包选择逻辑；改进矩阵乘法（mul_mat）的权重处理，减少计算错误；提供多平台预编译二进制，包括 macOS、Linux 等；继续支持 CPU 和 GPU 推理，覆盖多种架构

对比判断 暂无可信公开对比数据

适合谁 适合使用 llama.cpp 在 OpenCL 兼容 GPU（如 AMD、Intel）上进行本地推理的开发者、研究人员，以及需要优化量化模型性能的团队。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10827>

本简报基于候选源自动生成，仅供参考。