

重大 AI 更新提醒

09-06 | llama.cpp 修复 GDN 归一化，对齐参考实现

本期导读

本期聚焦 llama.cpp 最新 release b10829，修复了 Gated Delta Net (GDN) 的归一化实现，使其与 flash-linear-attention 和 transformers 保持一致，对 Qwen3-Next 等模型的推理准确性有重要影响。

已检查来源

GitHub Release

1. llama.cpp b10829: 修复 GDN 归一化从 max 到 rsqrt，对齐 FLA 实现

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 09-06 18:04 | 分数 7

是什么 这是 llama.cpp 的一个新版本（b10829），主要修复了 Gated Delta Net (GDN) 中 q/k 归一化的实现错误。具体来说，将归一化从使用 max 函数改为 rsqrt（平方根倒数），并采用了 flash-linear-attention 的 l2norm 定义。

通俗解释 想象你在调整音量，原来用的是 限制最大值 的方法，但正确做法是 按比例缩放。llama.cpp 之前对 GDN 的 q/k 归一化用了类似 限制最大值 的方法，而参考实现（如 flash-linear-attention）用的是 按平方根缩放。虽然通常差别不大，但在某些情况下会导致模型输出不准确。这次修复让 llama.cpp 与参考实现完全一致，就像校准了音量旋钮，确保声音不失真。

主要作用 修复 GDN 归一化实现与参考库不一致的问题，确保使用 Qwen3-Next 等模型的推理结果与官方实现对齐，提高模型输出的准确性和可靠性。

核心功能 将 GDN q/k 归一化从 max 改为 rsqrt，并采用 flash-linear-attention 的 l2norm 定义；修复了 epsilon 处理方式，现在 epsilon 在根号内，与参考实现一致；与 transformers 的修正（40842）保持一致，确保跨框架兼容性

对比判断 暂无可信公开对比数据

适合谁 适合使用 llama.cpp 进行本地推理的开发者，尤其是依赖 Qwen3-Next 或类似 GDN 架构模型的用户，以及关注推理准确性的研究人员。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10829>

本简报基于候选源生成，请以官方发布为准。