

重大 AI 更新提醒

09-07 | llama.cpp 性能优化更新

本期导读

本期聚焦 llama.cpp 最新 release b10840，该版本针对 CUDA 后端进行了性能优化，通过无分支计算和 L2 预取技术提升了特定硬件上的推理速度。适合关注本地推理性能的开发者优先关注。

已检查来源

GitHub Release

1. llama.cpp b10840: CUDA 无分支 Q4_K/Q5_K 解包加速 mmvq，DGX Spark 增加 L2 预取

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 09-07 09:31 | 分数 7

是什么 这是 llama.cpp 项目的一个新版本发布（b10840），主要针对 CUDA 后端进行了性能优化。具体来说，它改进了 Q4_K 和 Q5_K 量化格式的解包过程，使其使用无分支计算，从而在批量大小大于 1 时提升 mmvq（multi-model vector quantization）的性能。此外，该版本在 DGX Spark 硬件上增加了 L2 预取功能，以进一步加速推理。

通俗解释 想象一下，你在处理一个大型语言模型时，需要将模型数据从内存中快速读取到计算单元。Q4_K 和 Q5_K 是一种压缩模型数据的方法，但解压时需要执行一些条件判断，这就像在流水线上每次都要停下来检查一下，拖慢了速度。这个更新去掉了这些条件判断，让流水线顺畅流动，从而加快了处理速度。另外，对于 DGX Spark 这种特殊硬件，它增加了预取功能，就像提前把下一步要用的材料搬到手边，减少等待时间。

主要作用 该更新旨在提升 llama.cpp 在 CUDA 环境下的推理性能，特别是针对使用 Q4_K 和 Q5_K 量化模型的场景。对于在 NVIDIA GPU 上运行大型语言模型的开发人员，这可以带来更快的响应速度，尤其是在处理批量请求时。

核心功能 无分支计算：Q4_K 和 Q5_K 解包不再使用条件分支，减少了重复计算，提高了效率。；L2 预取：在 DGX Spark 上启用 L2 预取，通过提前加载数据到缓存，减少内存访问延迟。；自适应切换点：根据最新性能数据调整了 Q4_K 的切换点，以适应更多模型。；兼容性保护：预取功能仅对 Spark 启用，并针对 MUSA 和 HIP 进行了保护，避免影响其他架构。

对比判断 暂无可信公开对比数据。但根据提交信息，该优化在批量大小大于 1 时对 mmvq 性能有提升，且 DGX Spark 上通过预取获得额外加速。

适合谁 适合使用 llama.cpp 在 NVIDIA GPU 上部署大模型的开发人员，尤其是那些使用 Q4_K 或 Q5_K 量化模型并追求高吞吐量的场景。对于拥有 DGX Spark 硬件的团队，该更新能带来更明显的性能提升。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10840>

本简报基于候选源生成，所有信息均来自官方发布。