

重大 AI 更新提醒

09-08 | llama.cpp 发布 Vulkan 修复，提升 32 位平台兼容性

本期导读

本期聚焦 llama.cpp 最新 release b10857，该版本修复了 Vulkan 后端在 32 位平台上的句柄使用问题，增强了跨平台稳定性。对于依赖 Vulkan 加速的开发者，此更新值得关注。

已检查来源

GitHub Release

1. llama.cpp b10857: 修复 32 位目标上的 Vulkan-Hpp 句柄使用问题

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 09-08 06:36 | 分数 7

是什么 这是 llama.cpp 项目的一个 GitHub Release 版本，版本号为 b10857。llama.cpp 是一个用于运行大型语言模型（LLM）的 C++ 实现，支持多种后端，包括 Vulkan。本次发布主要修复了在 32 位平台上 Vulkan 后端的一个兼容性问题。

通俗解释 想象一下，你有一个工具箱（llama.cpp），里面有很多工具（后端），其中有一个叫 Vulkan 的工具，它负责让显卡加速计算。在 32 位的电脑上，这个工具在处理一些 把手 （句柄）时出了点问题，导致它不能正常工作。这次更新就是把这些 把手 修好，让 Vulkan 工具在 32 位电脑上也能顺利使用。具体来说，修复了两个小毛病：一是日志打印时无法正确显示这些 把手 ，二是调用某些函数时类型转换出错。

主要作用 解决 32 位平台上 Vulkan 后端的编译和运行问题，确保 llama.cpp 在更广泛的硬件上稳定运行，提升跨平台兼容性。

核心功能 修复 Vulkan-Hpp 句柄在 32 位平台上的类型转换问题；改进调试日志中 Vulkan 对象的输出方式；提供 macOS 和 iOS 的预编译二进制文件，方便用户直接使用

对比判断 暂无可信公开对比数据

适合谁 适用于使用 llama.cpp 并在 32 位系统（如某些嵌入式设备或旧电脑）上通过 Vulkan 进行推理的开发者，以及关注 Vulkan 后端兼容性的研究人员。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10857>

本简报基于 GitHub Release 信息生成，请以官方发布为准。