

重大 AI 更新提醒

09-09 | llama.cpp Vulkan 性能优化，IQ4_XS 推理提速

本期导读

本期聚焦 llama.cpp 最新版本 b10871，该版本为 Vulkan 后端新增 IQ4_XS 专用矩阵向量着色器，显著提升 RDNA4 显卡上的 token 生成速度。对于使用 AMD GPU 的本地大模型玩家，这是一次值得关注的性能升级。

已检查来源

GitHub Release

1. llama.cpp b10871: Vulkan 新增 IQ4_XS 专用 mat-vec 着色器，RDNA4 上 token 生成提速 6-17%

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 09-09 02:17 | 分数 7

是什么	这是 llama.cpp 的一个新版本（b10871），主要针对 Vulkan 后端进行了优化。它新增了一个专门用于 IQ4_XS 量化模型的矩阵 向量乘法着色器（shader），替换了之前通用的回退实现。IQ4_XS 是一种 4-bit 量化格式，用于在保持模型质量的同时减少内存占用。
通俗解释	想象一下，你有一个很大的书架（大语言模型），为了节省空间，你把每本书都压缩成小册子（量化）。IQ4_XS 就是一种压缩方式。现在，当你需要从书架上找信息时（推理），以前是用一个通用的方法去翻所有书，效率不高。这次更新相当于为这种特定压缩格式的书专门设计了一个更快的查找工具，所以找起来更快。具体来说，在 AMD 的 RDNA4 显卡上，生成 token 的速度提升了 6% 到 17%，取决于模型大小。
主要作用	解决 llama.cpp 在 Vulkan 后端处理 IQ4_XS 量化模型时性能不佳的问题，通过专用着色器优化矩阵向量乘法，从而提升 token 生成速度，让使用 AMD GPU 的用户获得更流畅的本地推理体验。
核心功能	新增 IQ4_XS 专用 mat-vec 着色器，替代通用回退路径；针对 RDNA4 架构优化，token 生成速度提升约 6-17%；移除无效的 n_it 展开分支，简化代码逻辑；提供 macOS、iOS、Linux 等多平台预编译二进制
对比判断	根据发布说明，在 RDNA4 显卡上，token 生成速度相比之前版本提升约 6-17%，具体取决于模型。没有与其他框架或硬件的对比数据。
适合谁	适合使用 AMD RDNA4 显卡（如 RX 7000 系列）进行本地大模型推理的开发者、AI 爱好者和研究人士，尤其是使用 IQ4_XS 量化模型并依赖 Vulkan 后端的用户。

直达链接 <https://github.com/qqml-org/llama.cpp/releases/tag/b10871>

本简报基于 GitHub Release 信息整理，请以官方发布为准。