

重大 AI 更新提醒

09-09 | vLLM 与 llama.cpp 同日发布重要更新

本期导读

本期聚焦 vLLM v0.29.0 与 llama.cpp 最新版本，涵盖推理引擎架构升级、新模型支持及 CUDA 优化，对 AI 推理性能与部署有显著影响。

已检查来源

GitHub Release

1. vLLM v0.29.0 发布：Model Runner V2 成为默认，支持 Hy4-preview 等新模型

来源 GitHub Release | 类型 GitHub Release | 主题 检索增强与向量模型 时间 09-09 03:54 | 分数 8

是什么 vLLM 是一个高性能的大语言模型推理与服务引擎，本次 v0.29.0 版本是其重要更新，包含 594 个提交，来自 277 位贡献者，其中 91 位是新人。核心变化是 Model Runner V2 (MRV2) 成为所有模型的默认执行路径，并新增了对多个新模型的支持。

通俗解释 可以把 vLLM 想象成一个高效的 AI 模型餐厅，它负责把训练好的大模型 端上桌（提供服务）。以前餐厅有两种厨房流程（MRV1 和 MRV2），现在 MRV2 成为标准，它更高效，比如能自动调整内存大小，减少浪费。同时，餐厅菜单新增了几道菜：腾讯的 Hy4-preview（一个 770B 参数但只有 49B 活跃的 MoE 模型）、Qwen3.8-Flash-Next、GraniteSWA 等。对于开发者来说，这意味着用 vLLM 部署这些新模型会更容易、更快。

主要作用 vLLM v0.29.0 旨在提升推理性能与可扩展性，通过 MRV2 的全面默认化，简化模型部署流程，并扩展对最新模型架构的支持，使开发者能够更高效地运行大规模语言模型。

核心功能 Model Runner V2 成为所有模型的默认执行路径，完成从 pooling 模型开始的全面推广。；新增 CUDA graph 内存分析功能，用于自动调整 KV cache 大小，优化显存利用。；支持 batch-sharded sampling，将每步 logits 内存减少至原来的 1/TP（张量并行度）。；新增对 Hy4-preview、Qwen3.8-Flash-Next、GraniteSWA 等模型的支持。

对比判断 暂无可信公开对比数据。

适合谁 适用于使用 vLLM 进行大模型推理部署的开发者、MLOps 工程师，以及需要支持最新模型架构的研究团队。

直达链接 <https://github.com/vllm-project/vllm/releases/tag/v0.29.0>

2. llama.cpp b10877 : 优化 RDNA3 上 MoE 模型的 CUDA 内核

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 时间 09-09 07:53 | 分数 7

是什么	llama.cpp 是一个流行的 C/C++ 实现的大语言模型推理框架，支持多种硬件。本次 b10877 版本主要针对 AMD RDNA3 显卡优化了路由 MoE（混合专家）模型的矩阵乘法（MMQ）分块大小，以提升推理性能。
通俗解释	MoE 模型就像一个有多个 专家 的团队，每次只激活部分专家。在 AMD 显卡上运行这类模型时，矩阵乘法是核心计算。这次更新通过调整计算分块（N-tiles）的大小，让计算更贴合硬件特性，从而减少等待时间，提升速度。对于在 AMD 显卡上运行 llama.cpp 的用户，这个更新可能带来性能提升。
主要作用	该版本旨在解决 llama.cpp 在 AMD RDNA3 显卡上运行 MoE 模型时的性能瓶颈，通过精细调整 CUDA 内核的分块策略，提高计算效率。
核心功能	针对 RDNA3 架构优化了路由 MoE 的 MMQ 分块大小。；分块大小根据典型专家宽度动态调整，以适配不同模型。；提供了 macOS 和 iOS 的预编译二进制文件，方便用户直接使用。
对比判断	暂无可信公开对比数据。
适合谁	适用于在 AMD RDNA3 显卡上使用 llama.cpp 运行 MoE 模型的开发者，以及对本地推理性能有极致追求的研究者。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10877>

3. llama.cpp b10876 : CUDA 量化组合可配置，提升编译灵活性

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 时间 09-09 06:45 | 分数 7

是什么	llama.cpp 的 b10876 版本改进了 CUDA 下的 Flash Attention 量化组合控制，用 GGML_FA_QUANTS 替代原来的 GGML_FA_ALL_QUANTS，允许用户更精细地控制编译哪些量化组合，并增加了运行时回退机制。
通俗解释	Flash Attention 是一种加速注意力计算的算法，支持不同的量化精度（如 4-bit、8-bit）。以前，llama.cpp 编译时要么全部编译，要么全部不编译，导致编译时间长或功能缺失。现在，你可以像点菜一样选择需要的量化组合，比如只编译 4-bit 和 8-bit，这样编译更快，而且如果遇到未编译的组合，程序会自动警告并回退到可用版本，不会崩溃。
主要作用	该版本旨在解决 llama.cpp 在 CUDA 平台上编译 Flash Attention 时量化组合不可控的问题，通过提供可配置选项，减少编译时间并增强运行时兼容性。
核心功能	引入 GGML_FA_QUANTS 宏，允许用户指定要编译的量化组合。；移除旧的 GGML_FA_ALL_QUANTS 标志，简化配置。；增加运行时回退机制，当遇到未编译的组合时给出警告并自动使用可用版本。；更新了构建文档，方便用户参考。
对比判断	暂无可信公开对比数据。
适合谁	适用于需要自定义编译 llama.cpp 的开发者，特别是那些希望减少编译时间或需要特定量化支持的场景。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10876>

以上信息基于 GitHub Release 官方发布，请以官方文档为准。