

重大 AI 更新提醒

09-09 | Google 发布 ADK for Kotlin 1.0、Transformers 新增 780B MoE 模型、IBM 推出时序基础模型

本期导读

本期聚焦 AI 智能体开发与模型发布。Google 正式推出 ADK for Kotlin 1.0，实现多平台智能体开发；Hugging Face Transformers 新增 HYV4 Hy4-Preview 780B MoE 模型；IBM 发布 Granite Time Series PatchTST-FM-r2 时序模型。

已检查来源

Google Developers Blog、GitHub Release、Hugging Face Blog

1. Google 发布 ADK for Kotlin 1.0：在 Kotlin、Android 及更多平台构建生产级 AI 智能体

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 09-09 13:59 | 分数 7

是什么 Google 正式发布 Agent Development Kit (ADK) for Kotlin 1.0，这是一个基于 Kotlin Multiplatform (KMP) 的智能体开发框架，支持在 Kotlin、Android 等平台构建多智能体 AI 应用。

通俗解释 想象你要开发一个能帮你订机票、查天气、安排日程的 AI 助手。ADK for Kotlin 就像一套积木，让你用 Kotlin 语言（Android 开发常用语言）快速搭建这个助手。它支持多智能体协作，比如一个智能体负责订票，另一个负责查天气，它们可以互相配合。而且它内置了与 Python 和 Java 版本相同的功能，意味着你可以在不同平台间复用代码。它还特别为 Android 优化，能调用手机上的本地模型，甚至利用手机的存储来记住你的偏好。

主要作用 解决 Kotlin/Android 开发者难以用原生语言构建生产级 AI 智能体的问题，提供与 Python/Java 版 ADK 一致的功能，降低多平台开发成本，并推动 Android 端 AI 应用落地。

核心功能 基于 Kotlin Multiplatform (KMP)，支持多平台复用代码；利用 Kotlin Symbol Processing (KSP) 实现零反射、类型安全的函数调用；支持高级编排能力，如人工介入工作流和上下文压缩；提供 Android 优先扩展：集成 LiteRT-LM 本地模型、Firebase AI 云推理、Room 会话持久化、AppSearch 语义记忆

对比判断 暂无可信公开对比数据

适合谁 适合 Kotlin 和 Android 开发者、移动端 AI 应用团队，以及希望在多平台复用智能体逻辑的开发者。

直达链接 <https://developers.googleblog.com/announcing-adk-for-kotlin-10-building-production-ready-ai-agents-in-kotlin-android-and-beyond/>

2. Hugging Face Transformers v5.17.0 新增 HYV4 Hy4-Preview : 780B 参数 MoE 模型 , 支持 1M 上下文

来源 GitHub Release | 类型 GitHub Release | 主题 开发者生态与数据工具 时间 09-09 10:42 | 分数 7

是什么	Hugging Face Transformers 发布 v5.17.0, 新增 HYV4 Hy4-Preview 模型, 这是一个 780B 参数的混合专家 (MoE) 语言模型, 每个 token 激活 49B 参数, 上下文窗口达 1M tokens。
通俗解释	想象一个超级智能助手, 它拥有 7800 亿个 脑细胞 (参数), 但每次思考只动用其中 490 亿个, 这样既聪明又高效。它采用 MoE 架构, 每个 token 会从 256 个专家中选择 8 个来处理, 就像你遇到问题时, 会从 256 位专家中挑 8 位最合适的来咨询。它还支持 100 万 token 的上下文, 相当于能一次性读完《三体》三部曲。此外, 它使用了 Multi-head Latent Attention (MLA) 和 DeepSeek Sparse Attention (DSA) 技术, 让注意力计算更高效, 还能通过共享索引减少重复计算。
主要作用	为 Transformers 用户提供最新的高性能 MoE 模型, 支持超长上下文, 适用于复杂推理、长文档处理等场景, 同时通过稀疏注意力降低计算成本。
核心功能	780B 参数 MoE, 激活 49B, 每层 256 个路由专家 1 个共享专家, 每个 token 路由到 8 个专家; 1M token 上下文窗口; Multi-head Latent Attention (MLA): 压缩键值到低秩潜在空间, 再扩展回每个查询头; DeepSeek Sparse Attention (DSA): 通过轻量索引器选择 top-k 键, 并支持层间共享索引
对比判断	暂无可信公开对比数据
适合谁	适合需要处理超长文本的 NLP 研究者、大型语言模型应用开发者, 以及关注 MoE 架构的机器学习工程师。

直达链接 <https://github.com/huggingface/transformers/releases/tag/v5.17.0>

3. IBM 发布 SOTA Granite Time Series PatchTST-FM-r2 模型, 采用商用友好许可

来源 Hugging Face Blog | 类型 官方发布 主题 开发者生态与数据工具 时间 09-09 10:36 | 分数 7

是什么	IBM 发布 Granite Time Series PatchTST-FM-r2, 这是一个时间序列基础模型, 宣称达到 SOTA 水平, 并采用商用友好许可。
通俗解释	时间序列数据就是按时间顺序记录的数据, 比如每天的股票价格、每小时的温度、每月的销售额。IBM 的这个模型就像是一个 预测专家, 你给它过去一段时间的销售数据, 它就能预测未来的趋势。它基于 PatchTST 架构, 将时间序列分成小块 (patch) 来处理, 能捕捉长期依赖。这个模型是 基础模型, 意味着它在大规模数据上预训练, 你可以微调它来适应你的特定数据, 比如预测电力负荷或交通流量。
主要作用	为时间序列预测任务提供高性能、可商用 (商用友好许可) 的基础模型, 帮助企业和研究者快速构建预测应用, 而无需从零训练。
核心功能	基于 PatchTST 架构, 适合长序列预测; 宣称达到 SOTA 性能; 商用友好许可, 便于企业采用; 作为基础模型, 支持微调以适应不同领域
对比判断	暂无可信公开对比数据
适合谁	适合需要时间序列预测的开发者、数据科学家, 以及金融、能源、零售等领域的企业团队。

直达链接 <https://huggingface.co/blog/ibm-research/ibm-releases-sota-granite-time-series>

以上信息基于候选源, 请以官方发布为准。