

重大 AI 更新提醒

09-10 | llama.cpp 更新 Windows ARM64 CUDA 构建，推理基础设施持续演进

本期导读

本期聚焦 llama.cpp 的最新 release：项目将 Windows on ARM (WoA) 平台的 CUDA 13.4 构建从 Developer Preview 归档切换到 CUDA 13.4.1 GA 再分发，意味着该平台的 GPU 加速推理构建进入正式可用阶段。对于在 Windows ARM64 设备上部署本地大模型推理的开发者，这是一次值得关注的构建链路更新。

已检查来源

GitHub Release

1. llama.cpp b10897：Windows ARM64 的 CUDA 13.4 构建切换到 13.4.1 GA 再分发

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 时间 09-10 12:59 | 分数 7

是什么	这是 ggml-org/llama.cpp 项目发布的一个新构建版本 b10897，核心变更是 CI 流程调整：把 Windows on ARM (WoA) 平台的 CUDA 13.4 构建，从原先使用的 Developer Preview 归档包，改为使用 CUDA 13.4.1 GA (General Availability, 正式发布) 再分发。该 release 同时提供 macOS Apple Silicon (arm64)、macOS Intel (x64)、iOS XCFramework、Ubuntu x64 (CPU)、Ubuntu arm64 (CPU) 等多平台预编译产物，方便用户直接下载运行。
通俗解释	llama.cpp 是一个让普通电脑也能跑大语言模型的推理引擎，它需要借助显卡厂商提供的底层工具包 (CUDA) 来加速计算。可以把它类比作做菜：llama.cpp 是菜谱和厨师，CUDA 是灶台和燃气。此前 Windows ARM64 这台灶台用的是厂商给的试用装燃气 (Developer Preview)，现在换成了正式上市销售的燃气 (13.4.1 GA)。对用户来说，菜谱没变，但灶台更稳定、更正规，出问题的概率更低，后续维护也更有保障。
主要作用	解决 Windows ARM64 平台上 CUDA 构建依赖非正式预览版组件的问题，让该平台的 GPU 加速推理构建建立在正式发布的 CUDA 13.4.1 GA 再分发之上，从而提升构建的稳定性、可维护性与长期可支持性，减少因依赖预览版组件带来的兼容性和供应链风险。
核心功能	1) 将 WoA CUDA 13.4 构建迁移到 13.4.1 GA 再分发，摆脱 Developer Preview 依赖；2) CI 构建流程更新，保证 Windows ARM64 产物持续可复现；3) 同一 release 覆盖 macOS、iOS、Linux 多平台预编译产物，便于跨平台部署；4) 提供 macOS Apple Silicon、macOS Intel、iOS XCFramework、Ubuntu x64/arm64 等下载项，其中 KleidiAI 加速版本当前处于 DISABLED 状态。
对比判断	暂无可信公开对比数据。候选摘要仅说明构建依赖从 Developer Preview 归档切换到 13.4.1 GA 再分发，未给出性能、速度或成本方面的量化对比。
适合谁	适合在 Windows ARM64 设备上部署本地大模型推理的开发者、需要在多平台分发 llama.cpp 预编译产物的工程团队，以及关注推理基础设施构建链路稳定性的研究者与运维人员。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10897>

本期仅收录 1 条候选，内容基于 GitHub Release 摘要整理，未对未提及的性能与成本做任何推断。