

重大 AI 更新提醒

09-11 | llama.cpp 针对 AMD RDNA4 的 Flash Attention 调优

本期导读

本期聚焦 llama.cpp 最新 release b10905，该版本围绕 CUDA/HIP 后端对 Flash Attention 做了针对性调优，重点覆盖 AMD RDNA4（gfx1201）平台。核心变化包括在 RDNA4 上为 head size 256 启用 mma Flash Attention、在 AMD WMMA 上优先使用整块 tile 的 FA 网格而非 stream-k，并修订了 stream_k 逻辑与内核选择逻辑。对于在 AMD 新卡上跑本地大模型推理的开发者，这是一次值得关注的性能向更新。

已检查来源

GitHub Release

1. llama.cpp b10905：为 AMD RDNA4 启用 head size 256 的 mma Flash Attention 并调优 HIP 内核选择

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 09-11 04:38 | 分数 7

是什么

这是 ggml-org/llama.cpp 的官方 release b10905，属于一次以推理性能为核心的更新。它修改了 CUDA/HIP 后端的 Flash Attention 实现：在 AMD RDNA4（gfx1201）架构上为 head size 256 启用了基于 mma 的 Flash Attention，并在 AMD WMMA 路径上优先采用整块 tile 的 FA 网格而不是 stream-k，同时修订了 stream_k 逻辑与内核选择逻辑。release 同时提供 macOS Apple Silicon、macOS Intel、iOS XCFramework 以及 Ubuntu x64 等平台的预编译产物。

通俗解释

可以把大模型推理想象成很多人同时查一本很厚的书。Flash Attention 是一种让查书过程更省内存、更快的方法，而 head size 可以理解为每次要同时翻看的页数。以前在 AMD 的新一代显卡（RDNA4）上，当每次要翻 256 页时，程序只能用较慢的方式处理；这次更新让这类显卡能用上更快的 mma 加速路径，并且把任务切分方式从 stream-k 改成整块 tile 网格，减少调度开销。结果就是在 AMD 新卡上跑本地模型时，注意力计算这一段更顺畅。

主要作用

它解决的是 AMD RDNA4 显卡在特定 head size（256）下 Flash Attention 无法走高效 mma 路径、以及 AMD WMMA 上网格调度策略不够优的问题。对于使用 llama.cpp 在 AMD 新卡上做本地推理的开发者，这次更新直接关系到注意力层的吞吐与延迟，因此值得关注并升级测试。

核心功能

1) 在 RDNA4（gfx1201）上为 head size 256 启用 mma Flash Attention；2) 在 AMD WMMA 上优先使用整块 tile 的 FA 网格而非 stream-k；3) 修订 stream_k 逻辑；4) 修订内核选择逻辑，并附带 macOS/iOS/Linux 多平台预编译产物。

对比判断

候选摘要未给出具体 benchmark、吞吐或延迟数字，暂无可信公开对比数据。

适合谁

适合在 AMD RDNA4 显卡上部署本地大模型推理的开发者、维护 llama.cpp 下游发行版的工程师，以及关注 HIP/CUDA 内核调优与 Flash Attention 实现的研究者。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10905>

本期仅基于候选源中真实存在的 GitHub Release 信息整理，未补充任何未经证实的 benchmark 或价格数据。