

重大 AI 更新提醒

09-15 | llama.cpp CUDA 后端新增行连续 SUM_ROWS 与 MEAN 支持

本期导读

本期聚焦 llama.cpp 的一次 CUDA 后端更新：b10984 版本为行连续张量补齐 SUM_ROWS 与 MEAN 算子支持，并复用共享 kernel、补充测试。这类改动直接影响本地大模型推理在 GPU 上的算子覆盖与正确性，对依赖 llama.cpp 做端侧私有化部署的开发者值得关注。

已检查来源

GitHub Release

1. llama.cpp b10984 : CUDA 后端支持行连续 SUM_ROWS，并新增 GGML_OP_MEAN 共享 kernel

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 09-15 08:41 | 分数 7

是什么 这是 ggml-org/llama.cpp 在 2026-09-15 发布的 b10984 构建版本，核心变更是为 CUDA 后端增加对行连续 (row-contiguous) 张量的 SUM_ROWS 支持，同时整理相关代码，并新增 GGML_OP_MEAN 以用同一套共享 kernel 处理行连续张量的均值运算，还补充了针对 MEAN 的 permute/slice 测试。发布页同时提供 macOS Apple Silicon (arm64)、macOS Intel (x64)、iOS XCFramework 以及 Ubuntu x64 (CPU) 等预编译产物下载。

通俗解释 可以把张量想成一张 Excel 表格：SUM_ROWS 就是 按行求和，MEAN 就是 按行求平均。过去 CUDA 后端只擅长处理内存里连续排列的整块数据，如果表格被 转置 或 切片 过，行与行之间在内存里不再紧挨着，算子就可能走不到 GPU 加速路径。这次改动让 GPU 也能直接对这类 行连续 的表格做求和与求平均，就像快递分拣线原本只认标准箱，现在也能处理被重新码放过的箱子，不必先搬回标准形态再算。对模型推理来说，很多归一化、注意力相关的计算都会用到按行统计，因此这类算子覆盖越全，GPU 路径就越不容易回退到 CPU。

主要作用 它解决的是 CUDA 后端在非标准内存布局下算子覆盖不足的问题：当张量经过 permute 或 slice 后变为行连续时，SUM_ROWS 与 MEAN 此前可能无法在 GPU 上高效执行，导致回退或报错。补齐这两个算子并复用共享 kernel，可以提升 llama.cpp 在 GPU 上运行大模型时的算子覆盖率与数值正确性，减少因布局问题引发的性能损失，对本地推理和私有化部署的稳定性有直接价值。

核心功能 第一，CUDA 后端新增对行连续张量的 SUM_ROWS 支持，扩展了 GPU 可处理的张量布局范围；第二，新增 GGML_OP_MEAN，并让 MEAN 与 SUM_ROWS 复用同一套共享 kernel，减少重复实现、便于维护；第三，代码经过整理并保留原有注释、增加 if/else 分支，兼顾可读性与兼容性；第四，补充了针对 MEAN 在 permute/slice 场景下的测试，提升回归保障。

对比判断 暂无可信公开对比数据。候选摘要未给出与旧版本或其他后端的 benchmark、速度或成本对比，仅说明新增算子支持与测试补充。

适合谁 适合使用 llama.cpp 在 NVIDIA GPU 上做本地或私有化大模型推理的开发者、负责 ggml/CUDA 算子实现的底层工程师，以及关注端侧推理框架算子覆盖与数值正确性的研究者与团队。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b10984>

本期刊收录 1 条高可信官方 release；候选未提供 benchmark 数据，性能影响需以实际部署验证为准。