

重大 AI 更新提醒

09-18 | NVIDIA 发布 AIPerf，面向规模化 LLM 推理的基准测试工具

本期导读

本期聚焦 NVIDIA 开发者博客发布的 AIPerf：一个用于在规模化部署场景下对 LLM 推理进行基准测试的工具。它针对的是 模型跑起来了，但到底快不快 这一实际工程问题，帮助团队用可复现的方式衡量推理性能，而不是凭直觉判断。对于正在做推理服务容量规划、性能调优和硬件选型的团队，这条更新值得关注。

已检查来源

NVIDIA Developer Blog

1. NVIDIA 发布 AIPerf：面向规模化 LLM 推理的基准测试工具

来源 NVIDIA Developer Blog | 类型 官方发布 主题 推理性能与基础设施 时间 09-18 14:04 | 分数 8

是什么

AIPerf 是 NVIDIA 在开发者博客中介绍的一套 LLM 推理基准测试方案，目标是在真实部署规模下衡量推理系统的表现。它关注的不是单次调用能不能返回结果，而是当模型已经部署到系统上、提示词开始产生响应之后，这套系统到底有多快、能承受多大负载。NVIDIA 在文中指出，很多人的直觉做法是直接发几个请求看响应时间，但这种方式无法反映规模化场景下的真实性能，AIPerf 正是为填补这一空白而提出。

通俗解释

可以把它类比为给推理服务做 体检 。假设你开了一家餐厅，厨房已经能出菜了，但客人一多就不知道上菜速度到底行不行。你不能只点一道菜掐个表就下结论，而要在不同客流下测出菜速度、排队长度和厨房瓶颈。AIPerf 做的就是类似的事：它用系统化的方式给 LLM 推理服务施加负载并测量表现，让你知道当前配置在真实压力下是快是慢，而不是靠 感觉挺快 来判断。

主要作用

它解决的是推理性能评估缺乏统一、可复现方法的问题。团队在部署模型后，往往需要回答容量规划、硬件选型、参数调优是否有效等问题，如果只靠零散的手动请求测试，结论既不可靠也无法横向比较。AIPerf 提供了一个面向规模化场景的基准测试路径，让性能讨论建立在可测量的数据之上，而不是主观印象。

核心功能

第一，面向规模化推理场景设计，强调在真实负载下评估系统表现，而非单次请求的响应时间。第二，针对 LLM 推理这一特定工作负载，关注提示词产生响应之后的持续性能表现。第三，提供可复现的基准测试方法，便于团队在不同配置、不同硬件之间做对比。第四，由 NVIDIA 开发者博客发布，与其推理栈和基础设施生态直接相关，便于落地到实际部署环境。

对比判断

候选摘要中未给出具体的 benchmark 数值、吞吐量、延迟或成本对比数据，暂无可信公开对比数据。

适合谁

适合正在部署和运维 LLM 推理服务的工程团队、负责推理性能调优和容量规划的开发者、需要做硬件选型与成本评估的基础设施团队，以及关注推理基准测试方法的研究人员。对于使用 NVIDIA 推理栈的团队，这条更新尤其值得跟进。

直达链接 <https://developer.nvidia.com/blog/benchmarking-llm-inference-at-scale-with-aiperf/>

本期仅收录 NVIDIA Developer Blog 一条候选，内容基于其公开摘要整理，未补充摘要之外的性能数据。