

重大 AI 更新提醒

09-20 | llama.cpp 为 Qwen4 在 CUDA 上启用稀疏 Flash Attention

本期导读

本期聚焦一条对本地推理社区影响直接的更新：llama.cpp 发布 b11062，在 CUDA 后端为 Qwen4 启用稀疏 Flash Attention (sparse fa)。这意味着使用 NVIDIA GPU 运行 Qwen4 系列模型的开发者，有望在长上下文场景下获得更低的显存占用与更快的注意力计算，同时继续沿用 llama.cpp 的量化与跨平台部署能力。

已检查来源

GitHub Release

1. llama.cpp b11062 : CUDA 后端为 Qwen4 启用稀疏 Flash Attention

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 时间 09-20 04:46 | 分数 7

是什么 这是 ggml-org/llama.cpp 的一个官方 release (b11062)，核心变更是 CUDA: enable sparse fa for qwen4 (#28770)。也就是说，在 llama.cpp 的 CUDA 推理路径中，针对 Qwen4 模型启用了稀疏 Flash Attention 支持。该 release 同时提供 macOS/iOS (Apple Silicon arm64、Intel x64、iOS XCFramework) 以及 Linux (Ubuntu x64、arm64、s390x 的 CPU 构建) 等多平台预编译产物，说明它延续了 llama.cpp 一贯的跨平台、本地优先的发布方式。

通俗解释 可以把注意力机制想象成开会时每个人都要和所有其他人逐一交换意见，人越多、发言越长，成本就越高。Flash Attention 是一种更省内存、更快的开会方式，它不把所有对话记录都摊在桌上，而是分块处理。稀疏 (sparse) 则更进一步：不是每个人都必须和所有人说话，而是只挑最相关的对象交流。对 Qwen4 这种模型，在 NVIDIA 显卡上启用稀疏 Flash Attention，就像给长文档问答、长代码补全这类上下文很长的任务减少无效社交，从而跑得更快、更省显存。

主要作用 它解决的是在本地或自建 GPU 环境运行 Qwen4 时的推理效率问题。长上下文场景下，注意力计算和 KV 缓存往往是显存与速度的主要瓶颈；通过 CUDA 上的稀疏 Flash Attention，开发者可以在不更换模型、不依赖云端 API 的前提下，降低显存压力并提升吞吐。对于需要私有化部署、数据不出本地的团队，这类底层优化直接决定了能否在单卡或有限显卡上跑起 Qwen4。

核心功能 1) CUDA 后端新增对 Qwen4 的稀疏 Flash Attention 支持，属于推理内核级优化；2) 延续 llama.cpp 的多平台发布，覆盖 macOS Apple Silicon、macOS Intel、iOS XCFramework 以及 Ubuntu x64/arm64/s390x 的 CPU 构建；3) 与既有量化、GGUF 生态兼容，用户可在本地直接替换二进制体验；4) 以官方 release 形式提供可下载产物，便于复现与回滚。

对比判断 候选摘要中未给出具体的 benchmark、吞吐提升百分比、显存节省数值或与其它推理框架的对比数据，因此暂无可信公开对比数据。可确认的对比信息仅限于：该版本在 CUDA 路径上为 Qwen4 启用了稀疏 Flash Attention，而此前该能力未在此 release 说明中体现。

适合谁 适合在 NVIDIA GPU 上本地部署或自建推理服务的开发者、负责私有化大模型落地的工程团队、研究长上下文注意力优化的研究者，以及使用 llama.cpp 跑 Qwen4 系列模型的个人开发者。对于只调用云端 API、不关心底层推理内核的团队，本条更新优先级较低。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b11062>

本期刊收录 1 条候选，信息以官方 release 说明为准；未在候选摘要中出现的性能数字与对比结论均未采用。