

重大 AI 更新提醒

09-20 | llama.cpp 针对 Gemma 4 的 CUDA Flash Attention 调优

本期导读

本期聚焦 llama.cpp 最新 release b11065：该版本在 CUDA 后端针对 Gemma 4 模型在 Ampere 及更新架构 GPU 上调整了 Flash Attention 实现。对于在本地或服务器上使用 NVIDIA 显卡运行 Gemma 4 的开发者，这次调优可能直接影响推理速度与显存占用，值得关注并测试。

已检查来源

GitHub Release

1. llama.cpp b11065：为 Gemma 4 在 Ampere 及更新 GPU 上调优 CUDA Flash Attention

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 时间 09-20 16:52 | 分数 7

- 是什么** 这是 ggml-org/llama.cpp 项目发布的一个新构建版本 b11065，核心变更是对 CUDA 后端的 Flash Attention (FA) 实现进行调优，专门面向 Gemma 4 模型，并要求 GPU 架构为 Ampere 或更新（如 RTX 30 系、40 系、A100、H100 等）。llama.cpp 是一个用 C/C++ 实现的高性能大语言模型推理框架，支持在 CPU、CUDA、Metal 等多种后端上运行量化模型。该 release 同时提供了 macOS、iOS、Linux 等多平台预编译二进制包。
- 通俗解释** Flash Attention 可以理解作为一种让模型在生成文字时 少读几遍笔记 的加速技巧。大模型在推理时，注意力机制需要反复比较当前词和之前所有词的关系，传统做法会把中间结果完整写进显存再读出来，速度慢且占显存。Flash Attention 把这一过程分块处理，减少显存读写。这次 llama.cpp 针对 Gemma 4 这个具体模型，在较新的 NVIDIA 显卡上重新调整了分块和计算策略，就像给一条特定流水线换了更合适的夹具，让 Gemma 4 在这类显卡上跑得更顺。
- 主要作用** 解决 Gemma 4 在 Ampere 及更新 NVIDIA GPU 上使用 CUDA 后端推理时，Flash Attention 未针对该模型充分优化的问题。对于依赖 llama.cpp 在本地或服务器部署 Gemma 4 的开发者，这次调优有望减少推理延迟、提升吞吐，并可能降低显存峰值占用，从而让相同硬件能承载更长上下文或更高并发。
- 核心功能** 第一，针对 Gemma 4 模型在 CUDA 后端定制 Flash Attention 的调优参数；第二，明确要求 Ampere 或更新架构 GPU，覆盖 RTX 30/40 系及数据中心 A100/H100 等；第三，随 release 提供 macOS Apple Silicon、macOS Intel、iOS XCFramework、Ubuntu x64/arm64/s390x 等多平台预编译包，方便直接下载使用；第四，属于 llama.cpp 持续迭代的官方构建，可与现有量化模型和 GGUF 生态配合。
- 对比判断** 候选摘要中未给出具体的 benchmark 数值、速度提升百分比或显存对比数据，因此暂无可信公开对比数据。建议开发者自行在相同硬件与 Gemma 4 量化版本下，对比 b11065 与前一版本的首 token 延迟和生成吞吐。
- 适合谁** 适合使用 llama.cpp 在 NVIDIA Ampere 及更新显卡上部署 Gemma 4 的开发者、本地推理爱好者、边缘与服务器部署团队，以及关注 CUDA 推理性能优化的研究人员。若你使用较老架构 GPU 或非 CUDA 后端，本次调优可能不直接适用。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b11065>

本期仅一条候选，信息来自 llama.cpp 官方 GitHub Release；具体性能收益请以本地实测为准。