

# 重大 AI 更新提醒

09-22 | vLLM v0.30.0 大版本与 llama.cpp CUDA 修复

## 本期导读

本期聚焦两条高可信开源推理栈更新：vLLM v0.30.0 带来 762 个提交、315 位贡献者，新增 DeepSeek-V4.1-Flash、GLM-5.3-Flash 等模型支持与 Fast Start 权重缓存；llama.cpp b11090 修复了 sm\_70（Volta）上的 CUDA tile 编译错误，恢复旧架构 GPU 的构建可用性。两条均来自官方 GitHub Release，适合关注推理部署与本地运行的开发者跟进。

## 已检查来源

GitHub Release: vllm-project/vllm v0.30.0、GitHub Release: ggml-org/llama.cpp b11090

## 1. vLLM v0.30.0 发布：新增 DeepSeek-V4.1-Flash 等模型支持与 Fast Start 权重缓存

来源 GitHub Release | 类型 GitHub Release | 主题 多模态理解 时间 09-22 00:20 | 分数 8

### 是什么

vLLM 是面向大语言模型推理与服务的开源高性能引擎，v0.30.0 是该项目的正式版本发布。本次发布包含来自 315 位贡献者（其中 104 位新贡献者）的 762 个提交，核心内容包括新增 DeepSeek-V4.1-Flash、DeepSeek-V4-Flash-Vision-Exp、GLM-5.3-Flash、K2-Horizon、Cohere Compass、Bailing V3 VL、Nanbeige4.2 等模型支持，并引入 Fast Start 机制：一个常驻的每 GPU 权重缓存守护进程，将量化后、按张量并行（TP）分片的权重保留在 GPU 内存中，重启引擎时通过 CUDA IPC 以 `load-format ipc_cache` 直接映射，而不再从磁盘重新加载。

### 通俗解释

可以把 vLLM 想象成一个 模型服务餐厅：厨房（GPU）要快速把菜（推理结果）端给客人。以前每次重新开张，厨师都要从仓库（磁盘）把食材（模型权重）重新搬一遍，很慢。v0.30.0 的 Fast Start 相当于让一个 仓库管理员 常驻厨房，把已经切好、分好份的食材一直放在手边；下次开张时直接用手边的食材，不用再跑仓库。同时这次还 上新了很多菜谱，比如 DeepSeek-V4.1-Flash、GLM-5.3-Flash 等新模型，vLLM 已经能直接服务它们。

### 主要作用

解决大模型推理服务在重启、扩缩容时重复加载权重导致启动慢的问题，并扩展对新模型与新硬件的支持，让团队能更快上线和切换模型。

### 核心功能

1) 新增 DeepSeek-V4.1-Flash 支持，整个 KV 通过 FlashMLA V4.1 记录以 MXFP8 存储在 SM100 上，并包含 DeepGEMM Mega-mHC 与 Engram DP 分片的异步 Engram 预取；2) 新增 DeepSeek-V4-Flash-Vision-Exp（含 ROCm 与 LoRA 支持）、GLM-5.3-Flash（含 EPLB）、K2-Horizon、Cohere Compass、Bailing V3 VL、Nanbeige4.2（Transformers 后端）等模型；3) Fast Start 持久化每 GPU 权重缓存守护进程，支持 `load-format ipc_cache` 通过 CUDA IPC 映射已量化、TP 分片权重；4) 新增 DeepSeek-V4 CPU 后端，包含 AVX512/AMX 稀疏 MLA、indexer、mHC 与 compressor 内核。

### 对比判断

候选摘要未给出与其它推理引擎的 benchmark、吞吐或成本对比数据，暂无可信公开对比数据；可确认的是本次发布规模为 762 个提交、315 位贡献者（104 位新贡献者）。

### 适合谁

适合需要部署大模型推理服务的平台工程师、MLOps 团队、推理性能优化研究者，以及使用 DeepSeek、GLM、K2 等模型并希望获得新硬件（SM100、ROCm、CPU AVX512/AMX）支持的开发者。

直达链接 <https://github.com/vllm-project/vllm/releases/tag/v0.30.0>

## 2. llama.cpp b11090 修复 CUDA sm\_70 ( Volta ) tile 编译错误

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 09-21 18:29 | 分数 7

|      |                                                                                                                                                                                                                                                                                                                        |
|------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 是什么  | llama.cpp 是 ggml-org 维护的、以 C/C++ 实现大模型推理的开源框架，b11090 是其滚动构建版本。本次变更修复了 CUDA 在 sm_70 ( Volta 架构 ) 上的 tile 编译错误：此前提交 1884824fd 引入的 5 参数 load_idmatrix 只定义了特定 tile 形状，导致 Volta 的 tile 不匹配；本次将该 5 参数 load_idmatrix 的 tile 形状泛化，使非 swizzle 分支对任意形状都转发到 3 参数 loader。提交说明称本地编译与测试已通过，并注明由 DeepSeek V4.1 Flash ( OpenCode ) 协助。 |
| 通俗解释 | llama.cpp 像一台 万能翻译机 ，能把大模型跑在各种电脑和显卡上。显卡有不同代际，Volta ( sm_70 ) 是较老的一代。之前有人给翻译机加了一个新零件 ( 5 参数 load_idmatrix ) ，但这个零件只适配新显卡的尺寸，老显卡装不上，编译就报错。这次修复相当于把零件做成 可调节尺寸 ，老显卡也能正常安装，于是 Volta 用户又能顺利编译和运行了。                                                                                                                           |
| 主要作用 | 恢复并保证在 Volta ( sm_70 ) 等旧架构 NVIDIA GPU 上编译 llama.cpp CUDA 后端的可用性，避免因 tile 形状不匹配导致构建失败，让老硬件用户继续使用最新代码。                                                                                                                                                                                                                  |
| 核心功能 | 1 ) 修复 5 参数 load_idmatrix 在 sm_70 上的 tile 编译错误；2 ) 将 5 参数 load_idmatrix 的 tile 形状泛化，使非 swizzle 分支对任意形状转发到 3 参数 loader；3 ) 提交说明本地编译与测试通过；4 ) 随版本提供 macOS Apple Silicon ( arm64 ) 、 macOS Intel ( x64 ) 、 iOS XCFramework 等预编译产物。                                                                                        |
| 对比判断 | 候选摘要未提供与其它推理框架或此前版本的速度、吞吐、成本对比数据，暂无可信公开对比数据；可确认的是该修复针对 sm_70 tile 编译错误，且本地编译与测试通过。                                                                                                                                                                                                                                     |
| 适合谁  | 适合在 Volta ( sm_70 ) 等旧架构 NVIDIA GPU 上本地运行或编译 llama.cpp 的开发者、边缘部署团队，以及维护 CUDA 后端内核的贡献者。                                                                                                                                                                                                                                 |

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b11090>

以上内容均基于候选 GitHub Release 摘要整理，未引入外部数据；具体性能与兼容性请以官方发布说明和实测为准。