

重大 AI 更新提醒

09-23 | llama.cpp 修复 Vulkan 后端符号冲突，MLflow 2.11.5 打通 Unity Catalog 制品传输

本期导读

本期聚焦两条开发者工具链更新：llama.cpp 发布 b11120，通过隐藏内部符号修复 Vulkan 后端在重复 dlopen 场景下的状态销毁崩溃；MLflow 发布 2.11.5 补丁版，为 Unity Catalog 模型注册表新增可选的 Databricks SDK Files API 制品上传下载路由。两条更新均面向本地推理与机器学习工程化场景，属于稳定性与集成能力改进。

已检查来源

GitHub Release

1. llama.cpp b11120：隐藏 Vulkan 内部符号，修复重复 dlopen 导致的状态销毁崩溃

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 09-23 02:07 | 分数 7

是什么

这是 ggml-org/llama.cpp 的官方 release b11120，核心变更是对 Vulkan 后端隐藏内部符号，只导出 GGML_BACKEND_API，从而避免 ggml_backend_load_all() 重复 dlopen 同一份库时内部符号互相抢占，导致析构函数提前销毁仍在使用的 vk_instance，后续设备查询触发 GGML_ASSERT 断言失败。该问题由 28732 引入，因为那次改动开始导出内部符号；本次修复恢复了 28732 之前的可见性策略，并关闭了 29138。

通俗解释

可以把 Vulkan 后端想象成一栋大楼，内部符号就是楼里的水电阀门。之前有人把阀门都标成了公共设施，于是当程序第二次加载同一栋楼时，新来的管理员误以为旧阀门归自己管，在离开时顺手把旧楼还在用的总闸关掉了，结果旧楼里正在查询设备的代码一开灯就跳闸。b11120 的做法是把阀门重新藏回楼内，只留一个对外的正式接口，这样重复加载也不会互相误关。

主要作用

解决 llama.cpp 在 Vulkan 后端上因重复加载动态库而引发的状态销毁与断言崩溃问题，提升多后端加载、插件式后端发现以及反复初始化场景下的稳定性，避免用户遇到难以定位的 GGML_ASSERT 失败。

核心功能

1) 将 Vulkan 后端内部符号改为隐藏可见性，仅导出 GGML_BACKEND_API；2) 修复 ggml_backend_load_all() 重复 dlopen/dlclose 时析构函数互相干扰的问题；3) 恢复 28732 之前的符号导出策略，保持向后兼容；4) 附带 macOS Apple Silicon、macOS Intel 与 iOS XCFramework 等平台构建产物。

对比判断

候选摘要未提供与其它版本或后端的 benchmark、速度、成本对比数据，暂无可信公开对比数据。

适合谁

适合在本地或边缘设备上使用 llama.cpp 进行推理的开发者、维护多后端加载逻辑的框架工程师，以及遇到 Vulkan 后端初始化崩溃、需要升级到稳定构建的团队。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b11120>

2. MLflow 2.11.5：为 Unity Catalog 模型注册表新增 Databricks SDK Files API 制品传输选项

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 09-23 01:17 | 分数 7

是什么	这是 MLflow 的官方补丁版本 2.11.5，主要新增一项可选功能：在 Model Registry / Models 模块中，允许将 Unity Catalog 模型注册表的制品上传与下载路由到 Databricks SDK Files API。该功能由 25986 引入，属于 opt-in 支持，意味着用户需要显式开启才会走这条新路径。
通俗解释	MLflow 管理模型时，除了记录模型本身，还要把模型文件存到某个地方，就像快递公司除了登记包裹信息，还要决定用哪条运输线路送货。以前 Unity Catalog 的模型制品走的是默认通道，现在 2.11.5 提供了一个可选的 新专线 ，通过 Databricks SDK 的 Files API 来收发文件。你可以继续用老通道，也可以主动切换到新专线，适合对传输路径有特定要求的团队。
主要作用	为使用 Unity Catalog 作为模型注册表后端的团队提供更灵活的制品传输方式，使其能够通过 Databricks SDK Files API 完成上传下载，便于统一权限、审计与网络策略，同时以 opt-in 方式避免影响现有工作流。
核心功能	1) 在 Model Registry / Models 中新增 opt-in 的 Unity Catalog 制品路由；2) 支持通过 Databricks SDK Files API 上传模型制品；3) 支持通过同一 API 下载模型制品；4) 作为 2.11.5 补丁版本发布，保持对既有行为的兼容。
对比判断	候选摘要未提供与旧传输路径在速度、成本或吞吐上的量化对比，暂无可信公开对比数据。
适合谁	适合在 Databricks 平台上使用 Unity Catalog 管理模型注册表的机器学习工程师、平台团队，以及需要统一制品传输权限与网络策略的 MLOps 从业者。

直达链接 <https://github.com/mlflow/mlflow/releases/tag/v2.11.5>

本期两条均为官方 GitHub Release，信息以候选摘要为准；未在摘要中出现的 benchmark、价格与性能数字均未采用。