

重大 AI 更新提醒

09-24 | llama.cpp 为 CUDA 后端补上 CONV_2D_DW 的 F16 卷积核支持

本期导读

本期聚焦 llama.cpp 的一次底层推理更新：CUDA 后端新增对深度可分离二维卷积（CONV_2D_DW）的 F16 半精度卷积核支持。这类改动不改变模型结构，但会直接影响多模态模型在 NVIDIA GPU 上的推理效率与显存占用，属于推理基础设施层面的实用优化。

已检查来源

GitHub Release

1. llama.cpp b11166 : CUDA 后端新增 CONV_2D_DW 的 F16 卷积核支持

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 09-24 15:40 | 分数 7

是什么

这是 ggml-org/llama.cpp 在 2026-09-24 发布的构建版本 b11166，核心变更是为 CUDA 后端增加了 CONV_2D_DW（深度可分离二维卷积）的 F16 半精度卷积核支持，对应 PR #29064。llama.cpp 是一个用 C/C++ 实现、面向本地与边缘设备的高效大模型推理框架，支持 CPU、CUDA、Metal 等多种后端，并同时提供 macOS、iOS、Linux 等多平台预编译产物。本次改动落在 CUDA 算子层，属于推理内核级别的补全，而不是模型权重或 API 层面的变化。

通俗解释

可以把深度可分离卷积理解成 先逐通道各自做一次小范围扫描，再用 1x1 卷积把通道信息混合起来，它比普通卷积省很多计算量，因此在视觉编码器、多模态模型里很常见。F16 就是半精度浮点，用 16 位而不是 32 位来存数字，好处是显存占用更小、GPU 计算吞吐更高，代价是数值精度略低。此前 CUDA 后端对这类卷积可能缺少 F16 专用实现，只能退回较慢或较费显存的路径；现在补上这个卷积核，相当于给 GPU 上跑视觉相关算子换了一条更顺的快车道。

主要作用

解决 CUDA 后端在深度可分离二维卷积上缺少 F16 原生支持的问题，让依赖这类卷积的模型（尤其是带视觉编码器的多模态模型）在 NVIDIA GPU 上推理时能更充分地利用半精度算力，减少因算子缺失导致的回退与额外开销。对本地部署和自建推理服务的团队来说，这类底层补全往往比上层参数调优更直接地影响吞吐和显存表现。

核心功能

第一，为 CUDA 后端新增 CONV_2D_DW 的 F16 卷积核实现，补齐半精度下的深度可分离卷积路径；第二，改动位于 ggml/llama.cpp 的 CUDA 算子层，与既有 CPU、Metal 等后端保持同一套图执行体系；第三，随版本提供 macOS Apple Silicon（arm64）、macOS Intel（x64）、iOS XCFramework、Ubuntu x64/arm64/s390x 等预编译产物，便于直接替换验证；第四，对应 PR #29064，可回溯具体实现与讨论。

对比判断

候选摘要未给出该卷积核相对旧路径的具体加速比、显存节省数值或 benchmark 结果，暂无可信公开对比数据。

适合谁

适合在 NVIDIA GPU 上本地部署或自建 llama.cpp 推理服务的开发者、负责多模态模型推理性能优化的工程师，以及关注 ggml CUDA 算子实现、需要评估是否升级到 b11166 的框架维护者。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b11166>

本期仅 1 条候选，均为 GitHub Release 来源；性能影响以实际硬件与模型实测为准。