

重大 AI 更新提醒

10-02 | Ray 2.59.0 与 llama.cpp b11344 同日发布，LLM 服务与推理底层同步更新

本期导读

本期聚焦两条来自 GitHub Release 的官方更新：Ray 2.59.0 将 Ray Data LLM 与 Ray Serve LLM 推进到 GA/Stable，并引入磁盘支撑的 external shuffle 与默认开启的 token 认证；llama.cpp b11344 修复了 CUDA 后端在 Volta 架构上的两个 Flash Attention 失败用例。两条更新分别覆盖分布式 LLM 服务 数据流水线与本地推理引擎的稳定性，适合关注生产部署与底层推理的开发者跟进。

已检查来源

GitHub Release

1. Ray 2.59.0 发布：Ray Data LLM 与 Ray Serve LLM 正式 GA，新增 external shuffle 与默认 token 认证

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 10-02 02:04 | 分数 8

是什么

Ray 2.59.0 是分布式计算框架 Ray 的官方版本更新。该版本将 Ray Data LLM 与 Ray Serve LLM 两套面向大语言模型的 API 从实验状态推进到 GA/Stable（65194），同时把底层推理引擎 vLLM 升级到 0.27.0（65351）。在数据侧，Ray Data 引入磁盘支撑的 external shuffle（shuffle_v2）模式，包含新的 external shuffle 运行时库与 task/operator 集合（64828、65144）、planner 集成（65499），并支持 Join 与 Aggregation（65897）；相关配置项由 hash_shuffle_v2 更名为 shuffle_v2（65411），压缩设置由 hash_shuffle_compression 更名为 shuffle_compression（65590）。在安全侧，Ray 对本地集群默认开启 token 认证：不带地址调用 ray.init() 时会启用认证，并在 ray/auth_token 不存在时自动生成 token；ray start --head 同样启用认证。

通俗解释

可以把 Ray 想象成一个调度大量机器干活的 包工头。以前它给大模型做数据准备和在线服务的那套工具还处于试用阶段，现在官方宣布它们已经稳定可用，可以放心用在生产环境。external shuffle 则像把临时堆积的中间数据从内存搬到硬盘上：当数据量大到内存装不下时，任务不会因为内存爆掉而失败，而是借助磁盘继续完成排序、连接和聚合。token 认证则类似给本地集群加了一道门禁，默认情况下只有拿到自动生成密钥的程序才能连上，避免同一台机器上其他进程随意调用。

主要作用

解决大模型数据流水线与在线推理服务在生产环境中的稳定性与可用性问题，让团队不必再依赖实验性 API；external shuffle 缓解大规模数据处理时的内存瓶颈；默认 token 认证降低本地集群被未授权访问的风险。

核心功能

1) Ray Data LLM 与 Ray Serve LLM 达到 GA/Stable，API 可正式用于生产；2) 新增磁盘支撑的 external shuffle（shuffle_v2），支持 Join 与 Aggregation，并完成 planner 集成；3) 升级 vLLM 至 0.27.0，跟进推理引擎能力；4) 本地集群默认开启 token 认证，自动生成 ray/auth_token。

对比判断

候选摘要未给出与上一版本或其他框架的 benchmark、速度或成本对比数据，暂无可信公开对比数据。

适合谁

适合使用 Ray 构建分布式数据流水线或 LLM 在线服务的平台工程师、MLOps 团队，以及需要在大规模数据上执行 shuffle、Join、Aggregation 的数据工程师；也适合关注 vLLM 集成与集群安全默认值的运维人员。

直达链接 <https://github.com/ray-project/ray/releases/tag/ray-2.59.0>

2. llama.cpp b11344 发布：修复 CUDA 后端两个 Volta 架构 Flash Attention 失败用例

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 10-02 03:54 | 分数 7

是什么	llama.cpp 的 b11344 版本是一次针对 CUDA 后端的修复发布，核心变更是修复两个在 Volta 架构上失败的 Flash Attention (FA) 用例 (29803)。该 release 同时提供多平台预编译产物，包括 macOS Apple Silicon (arm64)、macOS Intel (x64)、iOS XCFramework、Ubuntu x64 (CPU)、Ubuntu arm64 (CPU) 与 Ubuntu s390x (CPU) 等下载包，方便用户直接获取对应平台的二进制文件。
通俗解释	llama.cpp 是一个让普通电脑和服务器都能跑大模型的推理引擎。Flash Attention 是一种让模型在生成文字时更快、更省显存的注意力计算方式。Volta 是 NVIDIA 较早的一代 GPU 架构，之前在这类显卡上跑 Flash Attention 会出现两个用例失败的情况，相当于某些老显卡上模型计算会出错或跑不通。这次更新就是把这两个具体问题修好，让使用 Volta 显卡的用户也能正常使用该加速路径。
主要作用	解决 CUDA 后端在 Volta 架构 GPU 上 Flash Attention 用例失败的问题，提升老一代 NVIDIA 显卡上的推理正确性与可用性，并继续提供覆盖多平台的预编译二进制，降低用户自行编译的成本。
核心功能	1) 修复 CUDA 后端两个 Volta FA 失败用例 (29803)；2) 提供 macOS Apple Silicon、macOS Intel、iOS XCFramework 等苹果平台产物；3) 提供 Ubuntu x64、arm64、s390x 的 CPU 版本二进制；4) 附带 Attestations 等发布元数据。
对比判断	候选摘要未提供修复前后的性能、速度或显存对比数据，暂无可信公开对比数据。
适合谁	适合在 NVIDIA Volta 架构 GPU 上部署 llama.cpp 进行本地或服务端推理的开发者，以及需要为 macOS、iOS、Ubuntu 多平台快速获取预编译二进制的工程师和爱好者。
直达链接	https://github.com/ggml-org/llama.cpp/releases/tag/b11344

本期两条更新均来自 GitHub Release 官方渠道，具体行为与兼容性请以对应 release 页面说明为准。