

重大 AI 更新提醒

10-08 | Google 端侧 GPU 推理框架 ML Drift 发布，llama.cpp 同日连发多个 CUDA 优化与修复版本

本期导读

本期聚焦两条主线：Google AI Edge 推出跨平台 GPU 计算框架 ML Drift，把 OpenGL ES、OpenCL、Metal、WebGPU 等底层 API 统一抽象，降低端侧实时 ML 与生成式 AI 的开发门槛；llama.cpp 在 10-08 连续发布 b11510 至 b11513 四个版本，围绕 CUDA 后端的 top-k 算法选择、MMQ 越界读取、PAD kernel 行数上限以及 DFlash 输出头共享等问题做了性能优化与正确性修复。

已检查来源

Google Developers Blog、GitHub Release

1. Google AI Edge 发布 ML Drift：面向端侧 GPU AI/ML 推理的通用计算框架

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 10-08 14:36 | 分数 7

是什么	ML Drift 是 Google AI Edge 推出的高性能通用 GPU 计算框架，目标是在移动端和桌面端加速设备上的 AI 与机器学习推理。它把 OpenGL ES、OpenCL、Metal、WebGPU 等硬件与底层图形 计算 API 的差异抽象掉，让开发者无需为每种 GPU 后端单独写适配代码，就能构建实时、可交互的 ML 体验，覆盖从复杂视频特效到生成式 AI 的多种场景。
通俗解释	可以把它想象成一个 GPU 翻译官。过去开发者想让手机上的 AI 模型跑得快，得分别针对 Android 的 OpenGL ES、苹果的 Metal、浏览器的 WebGPU 写不同代码，就像去不同国家要学不同语言。ML Drift 把这些语言统一成一套接口，开发者只写一次，框架自动翻译给底层 GPU 执行。例如做实时视频背景虚化或手机端文生图，原本需要大量底层调优，现在可以直接调用 ML Drift 获得 GPU 加速。
主要作用	解决端侧 AI 推理长期存在的碎片化问题：不同平台、不同 GPU 厂商、不同图形 API 之间适配成本高，导致实时 ML 应用难以跨端落地。ML Drift 让开发者用统一方式调用 GPU 算力，缩短从原型到多平台发布的路径，也让生成式 AI 和实时视频特效在手机、桌面等设备上更可行。
核心功能	1) 跨平台 GPU 抽象：统一封装 OpenGL ES、OpenCL、Metal、WebGPU，屏蔽底层差异；2) 面向端侧推理优化：针对设备端 AI/ML 推理做高性能计算调度；3) 支持实时交互场景：可承载视频特效、生成式 AI 等对延迟敏感的任务；4) 覆盖移动与桌面：同一套框架可部署到手机和桌面平台。
对比判断	暂无可信公开对比数据。候选摘要未给出与其它端侧推理框架的 benchmark、速度或成本对比。
适合谁	适合做移动端 桌面端 AI 应用的开发者、需要在设备上跑实时视频特效或生成式 AI 的工程团队，以及希望减少多平台 GPU 适配工作量的端侧推理研究者。

直达链接 <https://developers.googleblog.com/ml-drift-next-gen-gpu-ai-ml-inference-at-the-edge/>

2. llama.cpp b11513 : CUDA 改进 top-k 算法选择，大行数场景改用 radix top-k

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 | 时间 10-08 14:18 | 分数 7

是什么	llama.cpp 发布 b11513 版本，核心变更是改进 CUDA 后端 top-k 算法的选择策略。它用基于 grid-over-rows 的 radix select 替换 CUB 的逐行 DeviceTopKKernel，并通过 GGML_CUDA_TOPK_RADIX_MIN_ROWS 控制启用条件；同时按形状选择 TOP_K 实现：短行用 bitonic，多个长行用 radix select，单个长行用 DeviceTopK 或 CUB argsort，阈值可在构建时覆盖。
通俗解释	top-k 是从一堆候选分数里挑出最大的 k 个，比如语言模型每生成一个 token 都要从几万个词里选出概率最高的几个。行数很多时，旧实现会为每一行单独启动一个 GPU kernel，启动次数爆炸。b11513 改成一次网格覆盖多行、用 radix select 批量处理，就像把 每户单独送快递 改成 一辆车按路线批量派送，大幅减少调度开销。
主要作用	解决大行数场景下 top-k 计算 kernel 启动次数过多、耗时过高的问题，同时让不同形状的输入自动匹配更合适的算法，提升 CUDA 上大模型推理的采样效率。
核心功能	1) radix top-k 替代 CUB 逐行 DeviceTopKKernel，按行数门控启用；2) 按形状自动选择 TOP_K 实现：短行 bitonic、多长行 radix select、单长行 DeviceTopK/CUB argsort；3) 阈值可在构建时覆盖，便于调优；4) bitonic 在行数能放进一个 block wave 时对最多 padded 1024 行继续使用。
对比判断	候选摘要给出明确数据：在 qwen4exp 34,816 tokens 场景下，top-k 从 1,671,253 次启动 5,761.8 ms 降至 2,329 次启动 941.8 ms。
适合谁	适合在 CUDA GPU 上部署大语言模型、关注采样阶段性能的推理工程师，以及维护 llama.cpp CUDA 后端的贡献者。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b11513>

3. llama.cpp b11512 : 修复 DFlash 输出头共享，从 GGUF 元数据读取 tied 输出权重

来源 GitHub Release | 类型 GitHub Release | 主题 检索增强与向量模型 | 时间 10-08 12:39 | 分数 7

是什么	llama.cpp 发布 b11512 版本，主要修复 DFlash 模型的输出头共享问题。变更包括：修复 DFlash output head sharing、让 dflash 从 GGUF 元数据读取 tied output weights、共享 tied word embedding 元数据，并移除 DFlash embedding head 的 fallback 逻辑。
通俗解释	很多语言模型会把输入词嵌入矩阵和输出预测矩阵 绑在一起 共用同一份权重，这叫 tied weights，能省显存。DFlash 模型在 llama.cpp 里之前没有正确共享这个输出头，导致权重读取或回退逻辑不一致。b11512 让模型从 GGUF 文件元数据里正确读出绑定权重，并去掉多余的兜底分支，相当于把 两本应该合订的书 真正合订起来，避免重复加载和潜在错误。
主要作用	解决 DFlash 模型在 llama.cpp 中输出头权重共享不正确的问题，保证 tied output weights 能从 GGUF 元数据正确读取，提升模型加载与推理的正确性，并清理不再需要的 fallback 路径。
核心功能	1) 修复 DFlash output head sharing；2) dflash 从 GGUF 元数据读取 tied output weights；3) 共享 tied word embedding 元数据；4) 移除 DFlash embedding head fallback。
对比判断	暂无可信公开对比数据。候选摘要未提供与其它版本或实现的性能、精度对比。
适合谁	适合使用 llama.cpp 加载 DFlash 系列模型、关心权重共享与 GGUF 元数据正确性的开发者和模型部署工程师。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b11512>