

重大 AI 更新提醒

10-09 | llama.cpp 聊天 API 重构，本地推理框架迎来接口层大改

本期导读

本期聚焦 llama.cpp 最新 release b11531，该版本对 chat 相关 API 进行了重构，涉及本地大模型推理与聊天接口的调用方式。对于依赖 llama.cpp 构建本地 AI 应用、智能体或开发者工具的团队，这次接口层调整可能影响现有集成代码，建议尽快评估升级路径。

已检查来源

GitHub Release

1. llama.cpp b11531 发布：chat API 重构，本地推理聊天接口迎来调整

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 10-09 11:38 | 分数 7

是什么	llama.cpp 是 ggml-org 维护的开源大语言模型推理框架，主打在 CPU、Apple Silicon、Linux 等多种硬件上高效运行量化模型。本次 release b11531 的核心变更是对 chat 相关 API 进行重构（PR #30210），并同步提供 macOS Apple Silicon、macOS Intel、iOS XCFramework、Ubuntu x64/arm64/s390x 等平台的预编译二进制包。
通俗解释	可以把 llama.cpp 想象成一个 万能翻译器，它让各种大模型能在普通电脑甚至手机上跑起来，而不需要昂贵的 GPU 服务器。这次更新相当于把这个翻译器的 聊天窗口 重新装修了一遍：以前你调用聊天功能的方式可能和现在不一样了，就像手机系统升级后，某些按钮的位置变了。如果你之前写好的程序直接调用旧接口，升级后可能需要按新方式改一改才能继续用。
主要作用	这次重构主要解决 chat API 在长期迭代中积累的接口一致性和可维护性问题，让开发者调用聊天补全、对话管理等能力时结构更清晰。对于正在用 llama.cpp 做本地 AI 助手、智能体或边缘推理产品的团队，及时跟进可以避免后续版本兼容性断裂，也能获得更稳定的接口行为。
核心功能	第一，chat API 重构，调整了聊天相关接口的组织方式；第二，继续提供多平台预编译包，覆盖 macOS Apple Silicon、macOS Intel、iOS XCFramework 以及 Ubuntu x64、arm64、s390x；第三，保留 KleidiAI 相关构建选项（当前标记为 DISABLED）；第四，通过 GitHub Release 附带 attestations，便于验证构建来源。
对比判断	暂无可信公开对比数据。候选摘要未提供与旧版本或其他推理框架在速度、内存占用或准确率上的量化对比。
适合谁	适合使用 llama.cpp 构建本地大模型聊天应用、智能体、桌面端或移动端 AI 工具的开发者；也适合在 Apple Silicon、Linux 服务器或 s390x 平台上做边缘推理部署的工程团队；对关注开源推理框架接口演进的研究者也有参考价值。

直达链接 <https://github.com/ggml-org/llama.cpp/releases/tag/b11531>

本期仅收录 1 条高可信 GitHub Release 更新；建议升级前先阅读 PR #30210 的接口变更说明并回归测试现有聊天集成。