重大 AI 更新提醒

10-12 | llama.cpp 修复 no-cache attention 的 KV 维度填充问题，恢复长序列 Flash Attention 加速

本期导读

本期聚焦 llama.cpp 的一次关键推理性能修复。该更新针对 no-cache attention 路径中 KV 维度未按 256 对齐的问题，避免 CUDA 内核因 head size 512 要求 FATTN_KQ_STRIDE 倍数而回退到 CPU，从而让 Flash Attention 在更多模型和序列长度下正常启用。对于依赖 llama.cpp 部署长上下文推理的开发者，这是一次值得关注的稳定性与性能改进。

已检查来源

GitHub Release

1. llama.cpp b11576：为 no-cache attention 的 KV 维度填充至 256，修复 Flash Attention 回退 CPU 问题

来源　GitHub Release | 类型　GitHub Release | 主题　推理性能与基础设施　时间　10-12 16:30 | 分数　7

是什么

这是 ggml-org/llama.cpp 项目在 GitHub 上发布的 b11576 版本更新。核心变更是对 no-cache attention 路径中的 KV 维度进行填充（pad）到 256。具体来说，no-cache 路径会构建一个 n_tokens, n_tokens] 的 mask，并直接传入未填充的 K 和 V，导致 FLASH_ATTN_EXT 看到 K- ne[1] 等于 n_tokens。对于 head size 为 512 的 CUDA 内核，要求维度必须是 FATTN_KQ_STRIDE 的倍数，否则该算子会回退到 CPU 执行；同时 fa auto 探测（仅 1 个 token）也会因此对这类模型禁用 flash attention。本次更新像 llama_kv_cache::get_n_kv 一样填充 mask，并将 K 和 V 用零填充到 mask 的 KV 维度，clef 也以相同方式构建并填充自己的 causal mask。

通俗解释

可以把 attention 计算想象成一场需要按固定座位数入座的会议：GPU 上的 Flash Attention 内核要求参会者（KV 维度）必须坐满 256 的整数倍座位，否则就拒绝开会，转交给速度慢得多的 CPU 来主持。llama.cpp 的 no-cache 路径之前直接带着 零散人数 的 K 和 V 去开会，导致 GPU 内核看到人数不对就罢工，于是大部分长度下都退回 CPU，连自动探测（只试 1 个 token）也会误判并关闭 Flash Attention。这次修复相当于给会议补足空座位（用零填充到 256 的倍数），让 GPU 内核愿意接手，长序列推理就能重新用上 Flash Attention 的加速。

主要作用

解决 no-cache attention 路径下因 KV 维度未对齐而导致 CUDA Flash Attention 内核回退 CPU 的问题，恢复 GPU 加速能力，并避免 fa auto 探测对 head size 512 模型错误禁用 Flash Attention。对于使用 llama.cpp 部署长上下文或大 head size 模型的用户，这能显著改善推理速度和 GPU 利用率。

核心功能

1）将 no-cache attention 的 mask 按 llama_kv_cache::get_n_kv 的方式填充，并把 K、V 用零填充到 mask 的 KV 维度；2）使 FLASH_ATTN_EXT 在 head size 512 时满足 FATTN_KQ_STRIDE 倍数要求，避免算子回退 CPU；3）修复 fa auto 探测（1 token）对这类模型错误禁用 flash attention 的行为；4）clef 以相同方式构建并填充 causal mask，保持路径一致性。

对比判断

候选摘要未提供与修复前相比的具体 benchmark、速度提升百分比或成本数据，暂无可信公开对比数据。

适合谁

适合使用 llama.cpp 进行本地或服务端推理的开发者、负责 GPU 推理性能优化的工程师，以及部署长上下文或 head size 512 模型（如部分大参数量模型）的团队。

直达链接　https://github.com/ggml-org/llama.cpp/releases/tag/b11576

本期仅收录 1 条高可信 GitHub Release 更新；性能提升幅度以官方后续 benchmark 为准。