重大 AI 更新提醒

10-13 | llama.cpp b11581 移除冗余张量拷贝，统一一元算子路径

本期导读

本期聚焦 llama.cpp 的一次底层推理优化更新：b11581 版本移除了模型实现中多余的 ggml_cont 调用，因为所有一元算子内核现已原生支持非连续张量输入。该改动覆盖 CUDA 一元内核，并针对 qwen3next 等模型恢复了 sigmoid 前的 cont_2d 以保证广播乘法正确性。对于关注本地推理性能与算子融合的开发者，这是一次值得留意的工程改进。

已检查来源

GitHub Release

1. llama.cpp b11581：移除冗余 ggml_cont 调用，所有一元算子内核已原生支持非连续张量

来源　GitHub Release | 类型　GitHub Release | 主题　推理性能与基础设施　时间　10-13 02:54 | 分数　7

是什么

这是 ggml-org/llama.cpp 项目发布的 b11581 构建版本，核心变更是从各模型实现中删除多余的 ggml_cont 调用。ggml_cont 是 GGML 张量库中用于把非连续内存布局的张量复制成连续布局的操作，过去在调用一元算子前常被显式插入以保证内核能正确读取数据。此次更新表明所有一元算子内核（包括 CUDA 后端）已经能够直接处理非连续张量，因此这些拷贝变得多余。同时，针对 qwen3next 模型，在 sigmoid 之后为广播乘法恢复了 cont_2d，并清理了 dflash 相关的 cont 调用，以确保数值语义不变。

通俗解释

可以把张量想象成一排书架上的书。有些书按顺序紧挨着放（连续内存），有些书被抽出来插到别的位置、中间留了空位（非连续内存）。以前计算程序只认紧挨着放的书，所以每次都要先把书重新摆整齐（ggml_cont 拷贝），既费时间又占地方。现在计算程序变聪明了，能直接读那些中间有空位的书，于是就不用再反复搬书了。不过在某些特殊操作（比如 qwen3next 里 sigmoid 之后的广播乘法）中，仍然需要把书摆整齐才能算对，所以代码里保留了必要的整理步骤。

主要作用

这项改动解决的是推理过程中不必要的内存拷贝开销问题。在本地大模型推理里，张量拷贝会消耗显存带宽和 CPU 时间，尤其在逐层执行大量一元算子（如激活函数、归一化）时，冗余拷贝会拖慢整体速度。移除这些调用可以让计算图更精简，减少内存分配与数据搬运，从而提升推理效率，并降低后端内核实现的复杂度。

核心功能

第一，所有一元算子内核现已支持非连续张量输入，覆盖 CUDA 后端，模型代码不再需要手动插入 ggml_cont。第二，针对 qwen3next 模型，在 sigmoid 之后恢复 cont_2d 以支持广播乘法，保证正确性。第三，清理了 dflash 相关的冗余 cont 调用，并更新了 src/models/qwen3next.cpp。第四，发布物包含 macOS Apple Silicon（arm64）、macOS Intel（x64）以及 iOS XCFramework 等平台构建。

对比判断

候选摘要中未提供与上一版本或其他推理框架的 benchmark、速度或成本对比数据，暂无可信公开对比数据。

适合谁

适合在本地或边缘设备上部署大模型的开发者、维护 GGML/llama.cpp 后端的工程师，以及研究推理算子融合与内存布局优化的研究者。对于使用 qwen3next 等模型的团队，这次更新直接关系到其推理路径的正确性与效率，值得跟进验证。

直达链接　https://github.com/ggml-org/llama.cpp/releases/tag/b11581

本期仅基于候选中的 GitHub Release 信息整理，未引入外部数据；建议在升级前于目标平台验证数值正确性与性能表现。