重大 AI 更新提醒

10-15 | Transformers v5.20.0 接入 Meta Muse Spark Open 与 Ling 3.0，llama.cpp v0.7.0 带来 MoE 专家 GPU 缓存与投机解码

本期导读

本期两条主线：一是 Hugging Face Transformers v5.20.0 官方新增 Meta 的 816B 多模态 MoE 模型 Muse Spark Open 以及 InclusionAI 的 Ling 3.0 Flash 混合 MoE 语言模型，模型侧继续向超长上下文与多模态智能体编码演进；二是 llama.cpp v0.7.0 在本地推理侧引入 LiliCorr 投机解码、GLM5-Next 的 MTP 以及面向 MoE 专家的主机内存 GPU 缓存，官方称在专家被卸载时可带来约 2.2 倍解码加速。NVIDIA 开发者博客同步给出 Muse Spark Open 在 GB300 NVL72 上的智能体编码工作流扩展说明。

已检查来源

GitHub Release - huggingface/transformers v5.20.0、GitHub Release - ggml-org/llama.cpp v0.7.0、NVIDIA Developer Blog

1. Transformers v5.20.0 新增 Meta Muse Spark Open 多模态 MoE 与 InclusionAI Ling 3.0 Flash

来源　GitHub Release | 类型　GitHub Release | 主题　智能体与开发者平台　时间　10-15 13:05 | 分数　8

是什么

Hugging Face Transformers 发布 v5.20.0，核心变更是新增模型支持。其一是 Meta 的 Muse Spark Open，这是一个多模态混合专家（MoE）模型，输入可同时包含文本、图像、音频和视频，输出为文本；总参数量 816B，每个 token 激活 42B 参数，上下文窗口最高 1,048,576 token 且跨模态共享，面向多文件编辑、调试和工具调用等智能体编码任务训练，提供 BF16 与 NVFP4 两种 checkpoint 格式。其二是 InclusionAI 的 Ling 3.0 Flash，这是一个混合 MoE 语言模型，解码器将五个 Kimi Delta Attention（KDA）层与一个多头注意力层分组组合。

通俗解释

可以把 MoE 想成一家大公司里有几百个专业小组，但每处理一个词只叫醒其中一小部分人干活，所以总人数（816B 参数）很多，实际每次出动的只有 42B，算力开销比同等规模的全激活模型低得多。多模态则像同一个人既能读文字、又能看图、听音频、看视频，再统一用文字回答。1M token 的上下文窗口意味着它一次能　记住　大约几十本中等厚度书的内容，因此可以在一个超长代码仓库里跨文件修改和调试，而不是每次只盯着一个函数。Ling 3.0 Flash 的 KDA 层与多头注意力交替分组，则类似在长文本里既保留快速线性扫描能力，又保留精确检索能力。

主要作用

解决的是超长上下文、多模态输入与智能体编码任务在统一模型框架内的落地问题。对使用 Transformers 的团队来说，不必自己写模型定义和权重加载逻辑，升级到 v5.20.0 即可直接调用这两个新架构，从而把多文件编辑、调试、工具调用等智能体编码流程建立在官方维护的实现之上，降低集成与维护成本。

核心功能

1）Muse Spark Open 支持文本、图像、音频、视频四类输入并统一生成文本，上下文窗口达 1,048,576 token 且跨模态共享；2）总参数 816B、每 token 激活 42B 的 MoE 结构，并提供 BF16 与 NVFP4 两种 checkpoint；3）针对多文件编辑、调试、工具使用等智能体编码任务训练；4）Ling 3.0 Flash 采用五个 KDA 层加一个多头注意力层的混合 MoE 解码器分组设计。

对比判断

候选摘要中明确给出的对比信息为：Muse Spark Open 总参数 816B、每 token 激活 42B、上下文窗口最高 1,048,576 token，并提供 BF16 与 NVFP4 两种 checkpoint 格式；Ling 3.0 Flash 的解码器为五个 KDA 层加一个多头注意力层分组。除此之外，摘要未提供与其它模型在 benchmark、速度或成本上的直接对比数据。

适合谁

适合需要在产品中集成超长上下文多模态模型的 AI 工程师、做智能体编码与工具调用研究的团队，以及使用 Hugging Face Transformers 作为统一推理与微调框架、希望第一时间跟进官方新架构支持的开发者；对关注 MoE 与线性注意力混合设计的模型研究者，Ling 3.0 Flash 的 KDA 分组结构也值得参考。

直达链接　https://github.com/huggingface/transformers/releases/tag/v5.20.0

2. llama.cpp v0.7.0 引入 LiliCorr 投机解码、GLM5-Next MTP 与 MoE 专家 GPU 缓存

来源　GitHub Release | 类型　GitHub Release | 主题　智能体与开发者平台　时间　10-15 12:13 | 分数　8

是什么

llama.cpp 发布 v0.7.0，新增 LiliCorr 投机解码技术，以及面向 GLM5-Next 的 MTP 支持；同时加入一项新的 GPU 缓存机制，用于把 MoE 专家权重保留在主机内存中，通过　　moe-cache-mib 参数控制，官方称在专家被卸载时可带来最高约 2.2 倍解码加速。该版本还批量新增模型支持，包括 K2 Horizon（dense 与 MoVA）、Prism Bonsai 2 27B、EmbeddingGemma-2（文本　视觉　音频）、LiquidAI d1/d1-omni 与 vLLM decision 2/d3 decision 模型、pplx-decider、MiniCPM-V 4.7、Nemotron Super 3.5 VL / Nemotron Bolt 以及 maion-coder。服务端重构了聊天会话 API（common_chat_session，基于 part 的格式化输出），改进 slot 与 prompt-cache 恢复行为，为新架构加入 decision-model 支持，默认端口改为 9931，Web UI 增加完整模型管理器，ggml 升级到 v0.27.0。

通俗解释

投机解码可以类比成　先让一个打字快的小助手猜出接下来几个词，再让大模型一次性检查并纠正，猜对的部分就直接采用，从而减少大模型逐字生成的开销。MoE 专家缓存则像把不常用但体积巨大的工具箱放在旁边的储物间（主机内存），需要时快速取到 GPU 上，而不是每次都从硬盘重新搬，所以当专家被卸载到主机内存时解码速度最高可提升约 2.2 倍。聊天会话 API 重构和 prompt-cache 恢复改进，则让多轮对话中重复的前缀不必反复计算，类似浏览器缓存已加载过的网页资源。

主要作用

解决本地与自托管推理场景中 MoE 大模型显存不足、解码速度慢以及多轮对话缓存复用效率低的问题。通过把专家权重缓存在主机内存并配合投机解码，用户可以在有限 GPU 显存下运行更大的 MoE 模型，同时获得可观的解码加速；批量新增模型支持与聊天会话 API 重构，则让开发者更容易把新架构模型接入现有服务端与 Web UI。

核心功能

1）新增 LiliCorr 投机解码与 GLM5-Next 的 MTP 支持；2）新增 MoE 专家主机内存 GPU 缓存，通过　　moe-cache-mib 配置，官方称专家卸载时最高约 2.2 倍解码加速；3）批量新增 K2 Horizon、Prism Bonsai 2 27B、EmbeddingGemma-2、LiquidAI d1/d1-omni、MiniCPM-V 4.7、Nemotron Super 3.5 VL 等模型支持；4）服务端重构 common_chat_session 聊天会话 API、改进 slot 与 prompt-cache 恢复、默认端口改为 9931，Web UI 增加模型管理器，ggml 升级至 v0.27.0。

对比判断

候选摘要中明确给出的对比数据为：在 MoE 专家被卸载的情况下，新的主机内存 GPU 缓存可带来最高约 2.2 倍解码加速。摘要未提供与其它推理引擎在 benchmark、吞吐或成本上的横向对比数据。

适合谁

适合在本地或自建服务器上部署大模型的开发者、需要在有限显存下运行 MoE 模型的团队，以及关注投机解码、MTP、prompt-cache 复用等推理优化技术的研究者；同时使用 llama.cpp 服务端与 Web UI 做多轮对话应用、希望获得更稳定会话恢复和模型管理能力的工程团队也会直接受益。

直达链接　https://github.com/ggml-org/llama.cpp/releases/tag/v0.7.0

3. NVIDIA 开发者博客：在 GB300 NVL72 上扩展 Meta Muse Spark Open 智能体编码工作流

来源　NVIDIA Developer Blog | 类型　官方发布　主题　智能体与开发者平台　时间　10-15 13:00 | 分数　7

是什么	NVIDIA 开发者博客发布文章，介绍如何在 NVIDIA GB300 NVL72 上扩展基于 Meta Muse Spark Open 的智能体编码工作流。文中说明 Muse Spark Open 是 Meta 推出的面向编码优化的 816B 混合专家（MoE）模型，激活参数 42B，上下文窗口为 1M token。
通俗解释	可以把智能体编码工作流理解成让 AI 像一名程序员一样，自己读代码、改多个文件、跑调试、调用工具，而不是只回答一个问题。Muse Spark Open 因为上下文窗口达到 1M token，能一次　看到　整个较大代码库，所以更适合这种跨文件连续操作。NVIDIA GB300 NVL72 则像一台为这类大模型专门准备的多 GPU 机房级机器，博客讲的是如何把这种大模型工作流放到这套硬件上规模化运行，让更多并发的编码智能体任务同时跑起来。
主要作用	解决的是把 816B 级 MoE 编码模型用于智能体编码工作流时的规模化部署问题。对于希望在生产环境中运行多文件编辑、调试和工具调用类编码智能体的团队，这篇文章给出了在 GB300 NVL72 平台上扩展该工作流的官方参考，帮助判断硬件选型与部署路径，而不必只依赖模型发布方的通用说明。
核心功能	1）围绕 Meta Muse Spark Open 这一 816B MoE、42B 激活参数、1M token 上下文窗口的编码优化模型展开；2）聚焦智能体编码工作流的规模化扩展；3）以 NVIDIA GB300 NVL72 作为目标硬件平台给出部署与扩展说明；4）由 NVIDIA 开发者博客发布，属于官方渠道的工程实践内容。
对比判断	候选摘要仅给出 Muse Spark Open 的模型规格（816B 总参数、42B 激活参数、1M token 上下文窗口），未提供与其它模型或硬件平台在 benchmark、速度、成本上的明确对比数据。
适合谁	适合负责大规模编码智能体基础设施的 AI 平台工程师、需要在数据中心级别硬件上部署超大 MoE 模型的 MLOps 团队，以及评估 GB300 NVL72 用于智能体编码场景的架构师与技术决策者；对研究智能体编码工作流扩展性的研究者也有参考价值。

直达链接　https://developer.nvidia.com/blog/scale-agentic-coding-workflows-with-metas-muse-spark-open-on-nvidia-gb300-nvl72/

本期内容均来自候选源中的官方 GitHub Release 与 NVIDIA 开发者博客，未引入候选之外的 benchmark、价格或日期信息；模型规格与加速数据以官方发布原文为准。