重大 AI 更新提醒

10-19 | llama.cpp 修复 SYCL 后端量化权重 get_rows 问题

本期导读

本期只有一条值得关注的更新：llama.cpp 发布 b11748 版本，修复了 SYCL 后端在处理重排（reordered）量化权重时 get_rows 的实现问题。该修复直接影响在 Intel GPU 等 SYCL 设备上运行量化模型的正确性，属于推理框架层面的稳定性补丁，而非新模型或新功能发布。

已检查来源

GitHub Release: ggml-org/llama.cpp b11748

1. llama.cpp b11748 修复 SYCL 后端重排量化权重的 get_rows 实现

来源　GitHub Release | 类型　GitHub Release | 主题　开发者生态与数据工具　时间　10-19 19:23 | 分数　7

是什么

这是 ggml-org/llama.cpp 的一个 GitHub Release（b11748），核心变更是一条针对 SYCL 后端的修复：修正 get_rows 在　重排后的量化权重　上的行为。llama.cpp 是用 C/C++ 实现、支持多种硬件后端（CPU、CUDA、Metal、SYCL 等）的本地大模型推理框架，SYCL 后端主要用于在 Intel GPU 等支持 SYCL 的设备上加速推理。该版本同时按惯例提供 macOS Apple Silicon、macOS Intel、iOS XCFramework、Ubuntu x64/arm64/s390x 等预编译产物。

通俗解释

大模型为了省显存，常把权重压成 4bit、5bit 这类低精度格式，叫量化。有些后端为了计算更快，会在加载时把权重按硬件喜欢的顺序重新排列，这就是　重排　。get_rows 是推理时按索引取出若干行权重的操作，比如查词嵌入表或做 MoE 路由时就会用到。如果重排后的权重仍按旧顺序去取行，取出来的数就是错的，模型输出会变得混乱甚至崩溃。这次修复相当于把　书架重新整理过之后，取书时仍按新编号去找　这件事做对了，让 SYCL 设备上的量化模型能正确出结果。

主要作用

解决 SYCL 后端在加载重排量化权重后 get_rows 取数错误的问题，避免在 Intel GPU 等 SYCL 设备上运行量化模型时出现结果错误或异常，保证该后端与其它后端行为一致。对依赖 SYCL 做本地推理的团队来说，这是一个应当跟进的正确性修复。

核心功能

1) 修复 SYCL 后端 get_rows 对重排量化权重的索引与反量化逻辑；2) 覆盖量化权重在重排布局下的取行路径，保证与未重排布局结果一致；3) 随版本提供 macOS arm64/x64、iOS XCFramework、Ubuntu x64/arm64/s390x 等多平台预编译包，便于直接替换验证。

对比判断

暂无可信公开对比数据；候选摘要未给出修复前后的性能或精度 benchmark。

适合谁

适合在 Intel GPU 或其他 SYCL 设备上部署 llama.cpp 做本地量化模型推理的开发者；维护 SYCL 后端适配的框架贡献者；以及需要验证量化权重重排路径正确性的推理引擎测试团队。

直达链接　https://github.com/ggml-org/llama.cpp/releases/tag/b11748

本期仅一条候选通过筛选；GitHub Release 类更新以正确性修复为主，建议 SYCL 用户升级后回归测试量化模型输出。