重大 AI 更新提醒

10-21 | MLflow 评测血缘增强与 llama.cpp 本地 TTS 服务上线

本期导读

本期聚焦两条开发者工具链更新：MLflow 3.17.2 在 genai.evaluate 运行中记录数据集、评分器与智能体血缘，并修复 Optuna 与 Spark 相关缺陷；llama.cpp b11781 为 server 新增 POST /tts 端点，让本地推理服务可直接输出语音。两者分别补强实验可追溯性与多模态服务能力。

已检查来源

GitHub Release: mlflow/mlflow v3.17.2、GitHub Release: ggml-org/llama.cpp b11781

1. MLflow 3.17.2 发布：genai.evaluate 运行记录数据集、评分器与智能体血缘

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 时间 10-20 22:51 | 分数 8

是什么

MLflow 3.17.2 是 MLflow 的一个补丁版本，核心变更是让 mlflow.genai.evaluate 在运行时把数据集、评分器（scorer）以及智能体（agent）的血缘信息记录到对应 run 中，同时修复了 MlflowSparkStudy 执行器采样器与批设置的重播种问题，以及 MlflowStorage 在 Optuna trial 数值保存前就标记完成的问题。

通俗解释

可以把 MLflow 想成实验记录本：以前你跑一次大模型评测，只记下分数，却说不清用的是哪份测试题、哪个打分程序、哪个智能体版本。现在 3.17.2 会自动把这三样 配料表 写进实验记录，就像做菜时把食材品牌和用量都记下来，日后复现或排查分数波动时能直接追溯。补丁还修了两个小毛病：Spark 上跑 Optuna 调参时随机种子和批大小会被正确重置，Optuna 试验也不会在结果还没存好时就被误标为完成。

主要作用

解决生成式 AI 评测中血缘信息缺失、实验难以复现的问题，并提升分布式调参与 Optuna 集成的稳定性，让团队在对比不同智能体或评分器时有据可查。

核心功能

1）在 mlflow.genai.evaluate 运行中自动记录数据集、scorer 和 agent 血缘；2）修复 MlflowSparkStudy 执行器的采样器重播种与批设置转发；3）修复 MlflowStorage 过早将 Optuna trial 标记为完成的问题；4）作为补丁版本保持向后兼容，升级风险低。

对比判断

暂无可信公开对比数据。

适合谁

适合使用 MLflow 做生成式 AI 评测与实验追踪的机器学习工程师、数据科学家，以及用 Optuna 做超参搜索、在 Spark 上跑分布式调参的团队。

直达链接 https://github.com/mlflow/mlflow/releases/tag/v3.17.2

2. llama.cpp b11781 发布：server 新增 POST /tts 端点，支持 TTS 模型语音输出

来源　GitHub Release | 类型　GitHub Release | 主题　智能体与开发者平台　时间　10-20 23:36 | 分数　7

是什么	llama.cpp 的 b11781 构建为 server 增加了 POST /tts 端点，用于 TTS 模型；同时在 mtmd 中新增音频输出流 API，补充文档，接入 mtmd_helper_model_can_chat，支持通过 form-data 上传 speaker_ref、向 API 暴露 seed，并修复 PCM 头、penalty_last_n、server_output_limits 与 pocket-tts 流式输出等问题，还新增了 TTS 的 server_schema 与路由。
通俗解释	llama.cpp 原本是一个在本地跑大模型的推理引擎，现在它内置的 HTTP 服务多了一个　语音合成　接口。你可以像调用聊天接口一样，向　tts 发一个请求，附上参考说话人音频（speaker_ref）和随机种子，服务就会把文字转成语音流返回。这好比给本地模型服务装了一个　朗读按钮　，不用再单独部署一套 TTS 系统；表单字段里的 seed 和 stream 也会被正确解析成整数和布尔值，避免　F seed=42 这类请求被拒绝。
主要作用	让 llama.cpp 的本地 server 直接承担文本转语音任务，减少额外服务依赖，并为多模态模型提供统一的音频输出流接口，方便开发者构建语音交互应用。
核心功能	1）新增 POST /tts 端点，支持 TTS 模型推理；2）mtmd 新增音频输出流 API，支持流式返回；3）支持 form-data 上传 speaker_ref 并暴露 seed 参数；4）修复 PCM 响应头、penalty_last_n、server_output_limits 与 pocket-tts 流式输出，并补充 server_schema 与路由文档。
对比判断	暂无可信公开对比数据。
适合谁	适合在本地或边缘设备部署 llama.cpp server 的开发者、做语音交互与多模态应用的研究者，以及希望用单一推理服务同时处理文本与语音的团队。

直达链接　https://github.com/ggml-org/llama.cpp/releases/tag/b11781

以上信息均来自候选 GitHub Release 摘要，未引入外部数据；升级前建议在测试环境验证兼容性。