重大 AI 更新提醒

10-27 | Google A2UI 推出可换推理格式与 A2UI Express，显著降低 token 用量与延迟

本期导读

Google Developers Blog 发布 A2UI 重要更新：新增可换推理格式，并推出 A2UI Express，通过将紧凑的 Python 风格语法编译为标准 A2UI JSON，最多减少 3 倍 token 用量并降低延迟。同时支持结合 TypeSafe Jev 系统决策模型的受控生成，可在 300 毫秒内渲染已知形状的界面。前端渲染器与组件目录无需改动，为生成式 UI 开发提供灵活的性能调节手段。

已检查来源

Google Developers Blog

1. Google A2UI 更新：可换推理格式与 A2UI Express 降低 token 用量和延迟

来源　Google Developers Blog | 类型　官方发布　主题　智能体与开发者平台　时间　10-27 15:21 | 分数　7

是什么

A2UI 是 Google 推出的生成式 UI 开发框架，本次更新为其增加了可换推理格式（swappable inference formats），并引入 A2UI Express。A2UI Express 允许开发者用紧凑的 Python 风格语法描述界面，再通过 Agent SDK 编译成标准 A2UI JSON，从而减少 token 消耗并降低延迟。此外，开发者还可以结合 TypeSafe 的 Jev 系统决策模型进行受控生成，快速渲染已知形状的屏幕，同时让较小模型流式输出文本。

通俗解释

可以把 A2UI 想象成一套　界面乐高说明书　，模型需要按标准 JSON 格式告诉前端怎么拼界面。以前模型要输出很长的 JSON，既费 token 又慢。A2UI Express 就像给模型一套更简短的　速记符号　，比如用类似 Python 的短句描述界面，再由 Agent SDK 自动翻译成标准 JSON。这样模型说话更少、更快，前端拿到的东西却没变。举个例子，原本要写一大段 JSON 才能生成一个带标题和按钮的卡片，现在用紧凑语法几行就能表达，翻译工作交给 SDK，前端渲染器完全不用改。

主要作用

解决生成式 UI 中模型输出冗长 JSON 导致 token 成本高、延迟大的问题，同时保持前端渲染器和组件目录不变，让开发者可以在不重构前端的情况下灵活调节性能与成本。

核心功能

1）支持可换推理格式，开发者可根据场景选择不同的推理输出格式；2）A2UI Express 使用紧凑 Python 风格语法，经 Agent SDK 编译为标准 A2UI JSON，最多减少 3 倍 token 用量并降低延迟；3）支持结合 TypeSafe Jev 系统决策模型进行受控生成，可在 300 毫秒内渲染已知形状的屏幕；4）兼容 Python、TypeScript 和 Dart，前端渲染器与组件目录无需改动。

对比判断

根据候选摘要，A2UI Express 最多使用少 3 倍的 token，并降低延迟；结合 Jev 系统决策模型的受控生成可在 300 毫秒内渲染已知形状的屏幕。暂无可信公开对比数据说明与其他生成式 UI 框架的横向性能差异。

适合谁

适合正在开发生成式 UI 的前端与全栈开发者、使用 Agent SDK 构建智能体界面的团队，以及需要在 Python、TypeScript 或 Dart 技术栈中平衡 token 成本与响应延迟的研究者和工程团队。

直达链接　https://developers.googleblog.com/fast-reliable-a2ui/

本期仅一条候选，信息均来自 Google Developers Blog 官方发布；性能数据以原文摘要为准，未做额外推断。