重大 AI 更新提醒

10-28 | llama.cpp 原生支持 LiquidAI LFM3 音频与全模态模型

本期导读

本期只有一条值得单独提醒的更新：llama.cpp 发布 b11941 版本，把 LiquidAI 的 LFM3-Audio-2B 与 LFM3-Omni-2B 纳入官方支持范围，并补齐了语音选择、配置转换与多模态推理路径。这意味着本地推理栈开始能直接跑 2B 级别的音频与全模态模型，对做端侧语音与多模态应用的开发者影响直接。

已检查来源

GitHub Release

1. llama.cpp b11941 新增 LiquidAI LFM3-Audio-2B 与 LFM3-Omni-2B 模型支持

来源　GitHub Release | 类型　GitHub Release | 主题　开发者生态与数据工具　时间　10-27 20:03 | 分数　7

是什么

这是 ggml-org/llama.cpp 的一个官方 release（b11941），核心变更是在其模型支持列表中加入 LiquidAI 的 LFM3-Audio-2B 和 LFM3-Omni-2B 两个模型，并配套修改了模型转换脚本、多模态（mtmd）推理路径与 TTS 语音选项。具体包括：转换脚本按 model_type 识别 LFM3-Audio 与 LFM3-Omni；读取官方发布的 LFM3-Audio config.json 布局；为 LFM3-Audio 的 depthformer 关闭 flash attention；在 llama-tts 与 server 的 tts 接口中增加 voice 参数；把 banned tokens 处理迁移为 logits bias 并移入 mtmd_helper。

通俗解释

可以把 llama.cpp 理解成一个 万能播放器 ，它本身不生产模型，但负责让各种开源模型在普通电脑、手机、树莓派上跑起来。以前这个播放器只认文字模型，现在它学会了认两个新格式：一个能听声音、说声音 （LFM3-Audio-2B），一个能同时处理声音和其他模态（LFM3-Omni-2B）。打个比方，就像你的本地播放器突然支持了带配音的有声书，而且还能选男声或女声 开发者只要加一个 tts-voice 参数，就能让模型用不同音色说话，不用自己再写一套音频前后处理代码。

主要作用

解决的是 本地跑音频 全模态模型门槛高 的问题。此前想在 llama.cpp 生态里用 LiquidAI 的 LFM3 系列，需要自己改转换脚本、处理 config 布局差异、绕开 flash attention 与音频编码器不兼容的问题。这个 release 把这些适配工作收进上游，让开发者可以直接用官方工具链加载模型、调用 TTS 接口，减少自研胶水代码和调试成本，也让端侧语音助手、离线多模态问答这类场景更容易落地。

核心功能

第一，新增 LFM3-Audio-2B 与 LFM3-Omni-2B 两个模型的加载与推理支持，覆盖音频理解与全模态输入。第二，转换脚本改为按 model_type 自动识别两个模型，并能正确读取官方发布的 LFM3-Audio config.json 布局，避免因 transformers 重写配置导致缺 key 的报错。第三，针对 LFM3-Audio 的 depthformer 关闭 flash attention，规避该结构下的兼容性问题。第四，TTS 增加 voice 选项：llama-tts 用 tts-voice，server 的 tts 接口用 voice 字段，对应模型卡提供的女声与男声。

对比判断

候选摘要中未给出与其它模型或其它推理框架的 benchmark、速度、显存占用或成本对比，暂无可信公开对比数据。

适合谁

适合在本地或端侧部署语音与多模态能力的开发者，例如做离线语音助手、TTS 应用、音频理解流水线的工程团队；也适合研究 2B 级别小模型多模态能力的研究者，以及维护 llama.cpp 下游发行版、需要跟进上游模型支持列表的打包者。对想在消费级硬件上验证 LFM3 系列、又不想自己写转换与推理适配代码的团队尤其有用。

直达链接　https://github.com/ggml-org/llama.cpp/releases/tag/b11941

本期仅一条候选通过筛选；所有信息均来自候选 release 说明，未补充外部 benchmark 或价格数据。