重大 AI 更新提醒

10-28 | PyTorch 2.15 分布式训练大改，LiteRT 让端侧 GPU 推理更快更小

本期导读

本期聚焦两项对开发者影响直接的更新：PyTorch 2.15.0 重写 NCCL 后端并默认启用，同时引入单边传输与 NVFP4 解码优化；Google Play services 中的 LiteRT 新增 GPU 推理与 CompiledModel API，官方称性能约提升 1.4 倍、应用体积减少约 8 MB。

已检查来源

GitHub Release、Google Developers Blog

1. PyTorch 2.15.0 发布：重写 NCCL 后端成默认，新增单边传输与 NVFP4 解码优化

来源　GitHub Release | 类型　GitHub Release | 主题　检索增强与向量模型　时间　10-28 12:09 | 分数　8

是什么

PyTorch 2.15.0 是 PyTorch 框架的一次版本发布，核心变化包括：重写后的 NCCL 后端成为默认分布式通信后端，并带有在挂起时转储状态的 flight recorder，可通过 TORCH_DIST_USE_NCCL2=0 或 nccl-legacy 回滚；torch.distributed 引入单边传输，包含 NIXL 后端和可被 CUDA graph 捕获的传输；FSDP2 与流水线并行获得更细粒度的内存与通信控制，支持对精度敏感参数使用 fp32、CUDA graph 捕获的梯度累积，以及梯度归约与计算重叠；在 NVIDIA Blackwell GPU 上通过少量改动实现更快的 4-bit（NVFP4）LLM 解码。

通俗解释

可以把分布式训练想象成很多人一起搬砖：NCCL 就是他们之间传砖的对讲机。这次 PyTorch 换了一台新对讲机（重写 NCCL 后端）并设为默认，还装了一个　黑匣子　（flight recorder），对讲机卡住时能自动记录现场，方便排查。单边传输则像允许一个人直接把砖放到对方手边，不必每次都喊　你接一下　，从而减少等待。FSDP2 的新控制让团队能更精细地决定哪些砖要轻拿轻放（fp32 精度）、哪些搬运可以提前排队（CUDA graph 捕获梯度累积），并把　传砖　和　砌砖　重叠起来。对普通用户来说，最终体现为训练大模型时更稳、更快、更省显存。

主要作用

解决大规模分布式训练中的通信瓶颈、挂起难排查、内存与通信调度不够精细等问题，并提升 Blackwell 平台上 4-bit LLM 解码速度，让训练和推理都更高效。

核心功能

1）重写 NCCL 后端默认启用，带挂起转储 flight recorder 与回滚开关；2）torch.distributed 单边传输，含 NIXL 后端和 CUDA graph 可捕获传输；3）FSDP2 与流水线并行支持 fp32 精度敏感参数、CUDA graph 捕获梯度累积、梯度归约与计算重叠；4）NVIDIA Blackwell GPU 上更快的 4-bit（NVFP4）LLM 解码。

对比判断

候选摘要未给出与旧版本的量化 benchmark 或速度对比数据，暂无可信公开对比数据；仅明确列出新能力与回滚路径。

适合谁

适合使用 PyTorch 做多卡　多机分布式训练的研究者与工程师、维护大规模训练集群的团队，以及在 NVIDIA Blackwell 上部署 4-bit LLM 推理的开发者。

直达链接　https://github.com/pytorch/pytorch/releases/tag/v2.15.0

2. Google Play services 中的 LiteRT 支持 GPU 推理：约 1.4 倍提速、应用体积减少约 8 MB

来源　Google Developers Blog | 类型　官方发布　主题　智能体与开发者平台　时间　10-28 15:43 | 分数　7

是什么	LiteRT 是 Google 的端侧机器学习运行时。此次更新让 Google Play services 中的 LiteRT 通过 ML Drift 提供 GPU 推理能力，并推出新的 CompiledModel API；开发者从打包二进制改为依赖 Play services 运行时后，应用体积可减少约 8 MB，同时能在数十亿设备上自动获得运行时更新。开发者只需更新依赖，并可使用 Android Studio 的 LiteRT skill 完成自动化迁移。
通俗解释	以前很多 Android 应用会把机器学习运行时的代码直接打包进 APK，就像每辆车都自带一台发动机，车自然更重。现在 LiteRT 把发动机放到 Google Play services 这个　公共加油站　里，应用只留一个接口，体积能小约 8 MB，而且发动机升级时不用重新发版。GPU 推理则像把计算任务交给显卡这个　多核大力士　，官方称比原来快约 1.4 倍。比如一个实时图像滤镜应用，可以更快出效果，安装包也更小。
主要作用	解决端侧 ML 应用体积大、运行时更新困难、GPU 推理性能不足的问题，让开发者以更低成本在大量 Android 设备上获得更快且可自动更新的推理能力。
核心功能	1）基于 ML Drift 的 GPU 推理，官方称约 1.4 倍性能提升；2）新的 CompiledModel API；3）改用 Play services 运行时后应用体积减少约 8 MB；4）运行时随 Play services 自动更新，并可用 Android Studio LiteRT skill 自动化迁移。
对比判断	候选摘要明确给出：GPU 推理性能约提升 1.4 倍，应用体积减少约 8 MB；未提供与其他推理框架的对比数据。
适合谁	适合在 Android 上部署端侧机器学习模型的移动开发者、需要控制安装包体积的应用团队，以及希望利用 GPU 加速推理且不想频繁发版更新运行时的工程团队。

直达链接　https://developers.googleblog.com/smaller-apps-and-faster-gpu-inference-with-litert-in-google-play-services/

以上内容基于候选源整理，未引入候选之外的事实；具体升级前请查阅官方发布说明并做好回滚预案。