重大 AI 更新提醒

10-31 | llama.cpp 发布 b12024，优化 LFM 短卷积张量形状

本期导读

本期聚焦 llama.cpp 的 b12024 版本更新。该版本针对 LFM 模型中的短卷积（short convolution）操作，将矩阵乘法从 3D 张量改为 2D 张量进行 reshape，以提升计算效率。这是面向本地推理框架的底层优化，适合关注模型部署性能的开发者。

已检查来源

GitHub Release: ggml-org/llama.cpp b12024

1. llama.cpp 发布 b12024：为 LFM 短卷积将矩阵乘法改为 2D 张量 reshape

来源　GitHub Release | 类型　GitHub Release | 主题　智能体与开发者平台　时间　10-31 16:35 | 分数　7

是什么

这是 ggml-org/llama.cpp 的一个 GitHub Release（b12024），核心变更是针对 LFM 模型中的短卷积（short convolution）操作，将矩阵乘法（mm）的输入从 3D 张量 reshape 为 2D 张量后再执行，从而改变计算路径。该版本同时提供了 macOS（Apple Silicon arm64、Intel x64）、iOS XCFramework、Linux（Ubuntu x64/arm64/s390x CPU）等多平台预编译二进制包。

通俗解释

可以把张量想象成多维数组：3D 张量像一摞二维表格，2D 张量就是单张表格。很多矩阵乘法库对二维表格的处理更直接、更高效。llama.cpp 这次在 LFM 模型的短卷积环节，先把三维数据　压平　成二维再算乘法，算完再恢复形状，就像把一摞纸先摊成一张大纸来盖章，盖完再裁回一摞，减少中间环节的开销。

主要作用

解决 LFM 模型在 llama.cpp 推理时短卷积操作中矩阵乘法的张量形状不匹配或效率不高的问题，通过 reshape 到 2D 让矩阵乘法走更成熟的 2D 计算路径，从而改善该模型在本地推理框架中的执行效率与兼容性。

核心功能

1）针对 LFM 短卷积（lfm sc）将矩阵乘法输入从 3D 张量 reshape 为 2D 张量；2）覆盖 macOS Apple Silicon（arm64）、macOS Intel（x64）、iOS XCFramework、Ubuntu x64/arm64/s390x CPU 等多平台预编译包；3）属于 llama.cpp 持续集成发布流程中的常规构建版本，附带 attestations 与网站链接。

对比判断

候选摘要中未提供与前一版本或其他推理框架的 benchmark、速度、成本对比数据，暂无可信公开对比数据。

适合谁

适合在本地或边缘设备上部署 LFM 系列模型的开发者、使用 llama.cpp 进行推理优化的工程师，以及关注 ggml 底层张量运算与多平台构建的研究者；对需要 macOS/iOS/Linux 多平台二进制分发的团队也有参考价值。

直达链接　https://github.com/ggml-org/llama.cpp/releases/tag/b12024

本期仅一条候选，信息来自 llama.cpp 官方 GitHub Release；未包含未经验证的性能数据。