重大 AI 更新提醒

11-02 | vLLM v0.33.0rc3 发布：927 次提交、十余款新模型接入、升级 PyTorch 2.14 并停发 CUDA 12.9 构建

本期导读

本期只有一条但分量很重：vLLM 发布 v0.33.0rc3 候选版本，一次性合入 927 次提交、来自 389 位贡献者（其中 122 位是新贡献者）。这次更新同时带来大批新模型支持、PyTorch 2.14 升级，以及 CUDA 12.9 构建的正式停发，对正在做推理部署的团队属于需要提前评估的破坏性变更。

已检查来源

GitHub Release

1. vLLM v0.33.0rc3 发布：新增 Reflection Beam-1.0 等十余款模型，升级 PyTorch 2.14，仅保留 CUDA 13.0 构建

来源　GitHub Release | 类型　GitHub Release | 主题　多模态理解　时间　11-02 04:10 | 分数　8

是什么

这是 vLLM 项目 v0.33.0 的候选发布版本（rc3）。vLLM 是当前主流的开源大模型推理与服务框架，本次版本包含 927 次提交、389 位贡献者（122 位新贡献者）。核心内容包括：新增 Reflection Beam-1.0（501B MoE、23B 激活参数）及其 DFlash2 drafter、Yandex AliceAI-Foundation-80B-A3B、Recursive Flint（40B MoE、2.5B 激活）、Muse Spark Open、Step-5 Preview、NVIDIA Alpamayo 2 Super、Nemotron-Labs Dory1.0-4B、Nemotron Parse 3.5、MiniCPM-OCR 1.0、Domyn Edge 以及 ColUltraVBERT 视觉文档检索模型；框架整体升级到 PyTorch 2.14.0，配套 torchvision 0.29.0 与 Triton 3.8.0；同时停止发布 CUDA 12.9 的 wheel 和　cu129 系列镜像，只提供 CUDA 13.0 产物，并引入 libtorch ABI 稳定的 CUDA wheel。

通俗解释

可以把 vLLM 理解成一个　模型服务引擎　：你手里有一个几十亿甚至上千亿参数的大模型，想让它同时服务很多用户、又快又省显存，就需要这类框架来调度。这次更新好比一个大型应用商店的年度大版本：一方面上架了一大批新　商品　（新模型），比如 501B 参数但每次只激活 23B 的 Reflection Beam-1.0，这类 MoE 模型像一家大公司里只叫醒需要干活的部门，能省算力；另一方面把底层　发动机　从旧版 PyTorch 换成 2.14，并规定以后只提供适配 CUDA 13.0 的安装包。对使用者最直接的影响是：如果你还在用 CUDA 12.9 环境，升级后原来的安装命令会找不到对应包，需要先升级驱动和 CUDA 工具链。

主要作用

这次发布主要解决三类问题：一是让 vLLM 尽快支持社区新出的模型架构（尤其是 MoE、视觉文档检索、OCR 等方向），避免用户自己写适配代码；二是跟进 PyTorch 2.14 与 Triton 3.8 的生态升级，获得新算子与编译优化；三是通过停发 CUDA 12.9 构建、引入 libtorch ABI 稳定的 wheel，收敛发布矩阵、降低长期维护成本。对推理团队来说，它值得看是因为这是一次包含破坏性变更的大版本，需要提前做兼容性评估。

核心功能

第一，新模型覆盖广：Reflection Beam-1.0（501B MoE、23B 激活）及其 DFlash2 drafter、Yandex AliceAI-Foundation-80B-A3B、Recursive Flint（40B MoE、2.5B 激活）、Muse Spark Open、Step-5 Preview、NVIDIA Alpamayo 2 Super、Nemotron-Labs Dory1.0-4B、Nemotron Parse 3.5、MiniCPM-OCR 1.0、Domyn Edge、ColUltraVBERT 视觉文档检索模型等。第二，运行时栈升级到 PyTorch 2.14.0，配套 torchvision 0.29.0 与 Triton 3.8.0。第三，构建矩阵收敛：release wheel 与镜像仅提供 CUDA 13.0，不再发布 CUDA 12.9 wheel 及　cu129 / -cu129-ubuntu2404 镜像。第四，引入 libtorch ABI 稳定的 CUDA wheel，减少因底层库版本不匹配导致的安装问题。

对比判断

候选摘要中未给出吞吐、延迟或成本方面的量化对比数据，仅明确了版本层面的变化：相对此前版本，本次新增十余款模型支持、PyTorch 由旧版本升至 2.14.0、Triton 升至 3.8.0，并且 CUDA 12.9 构建被移除、只保留 CUDA 13.0。除此之外暂无可信公开对比数据。

适合谁

适合正在用 vLLM 做线上推理服务的平台与基础设施团队（需要评估 CUDA 13.0 迁移和 PyTorch 2.14 兼容性）；适合想部署 Reflection Beam-1.0、Step-5 Preview、MiniCPM-OCR 1.0、ColUltraVBERT 等新模型的研究者与工程团队；也适合关注 MoE 推理、视觉文档检索和多模态 OCR 方向、希望基于开源框架做二次开发的数据科学与算法人员。

直达链接　https://github.com/vllm-project/vllm/releases/tag/v0.33.0rc3

本期仅一条候选，且为候选发布版本（rc3），正式上线前建议先在测试环境验证 CUDA 13.0 与 PyTorch 2.14 的兼容性。