重大 AI 更新提醒

11-04 | llama.cpp v0.9.0 发布：FP8 量化、统一 KV cache 多序列推理与四种新模型架构

本期导读

本期只聚焦一条高信号更新：llama.cpp 发布 v0.9.0，同时改动量化格式、注意力算子、KV cache 调度、模型架构支持与音频能力，底层 ggml 也升到 v0.29.0。对本地推理和多序列服务部署的开发者来说，这是一次覆盖面较广的版本升级。

已检查来源

GitHub Release: ggml-org/llama.cpp v0.9.0

1. llama.cpp v0.9.0 发布：新增 OCP FP8 E4M3 量化、flash_attn_ext_rows 算子与四种新架构支持

来源　GitHub Release | 类型　GitHub Release | 主题　智能体与开发者平台　时间　11-04 07:08 | 分数　8

是什么	这是 ggml-org/llama.cpp 的 v0.9.0 官方 release。llama.cpp 是用 C/C++ 实现的大模型推理引擎，底层依赖 ggml 张量库，广泛用于在 CPU、CUDA、Metal、Vulkan 等后端上跑本地模型。本次更新加入 OCP FP8 E4M3 张量类型（饱和模式）及配套转换工具和新的 ftype，新增 flash_attn_ext_rows 算子让统一 KV cache 在多序列推理时更高效，并提供通用的批量张量拷贝 API；同时支持 Clover、Limite、Metis-1.6、Mistral Large 4 四种新架构，音频侧扩展 Chatterbox TTS、Nemotron 3.5 Transcribe 和 Pocket TTS 预置音色，Gemma 4 E2B/E4B 获得 prefill 优化，ggml 升级到 v0.29.0。
通俗解释	可以把 llama.cpp 想成一个　万能播放器　，专门播放各种大模型。模型文件很大，直接跑很吃内存，所以通常先做　压缩　，也就是量化，把每个数字从 16 位压到 8 位甚至更低。这次新增的 FP8 E4M3 就是一种 8 位压缩格式，好处是精度损失小、显存占用低，而且有硬件加速时算得更快。另一个改动是 KV cache：模型聊天时要记住前文，这份　记忆　占空间很大。以前多个用户同时提问，每人各存一份记忆很浪费；新的 flash_attn_ext_rows 算子让多个人共享同一份记忆也能高效计算，类似一间教室共用一块黑板而不是每人发一块。
主要作用	解决三类实际问题：一是让模型量化多一种低精度、高兼容的格式选择，便于在支持 FP8 的硬件上省显存、提吞吐；二是让统一 KV cache 在多序列、多用户并发场景下真正可用，降低长上下文服务的显存开销；三是扩大模型覆盖面，让新发布的架构不用等社区适配就能直接加载，同时补齐语音合成与转写能力。对自建推理服务的团队，这些改动直接影响部署成本和并发能力。
核心功能	1) 新增 OCP FP8 E4M3 张量类型（饱和模式），附带转换辅助函数和新的 ftype，量化流程可直接选用；2) 新增 flash_attn_ext_rows 算子，使统一 KV cache 在多序列推理中保持高效；3) 提供通用批量张量拷贝 API，简化后端间数据搬运；4) 支持 Clover、Limite、Metis-1.6、Mistral Large 4 四种新架构，并扩展 Chatterbox TTS、Nemotron 3.5 Transcribe、Pocket TTS 预置音色等音频能力，Gemma 4 E2B/E4B 获得 prefill 优化，ggml v0.29.0 带来 NCCL 多节点张量并行及 CPU、CUDA、SYCL、Metal、Vulkan、OpenCL、Hexagon 各后端性能改进。
对比判断	候选摘要未给出具体 benchmark 数值、吞吐提升比例或显存节省数据，仅说明 Gemma 4 E2B/E4B 获得　major prefill optimizations　、ggml 在各后端有　performance work　，因此暂无可信公开对比数据。
适合谁	适合在本地或私有环境部署大模型的开发者、负责推理服务容量与成本的工程团队、需要多用户并发长上下文服务的后端工程师，以及关注量化格式与 ggml 后端适配的研究者和社区贡献者；使用 Gemma 4、Mistral Large 4 等新架构或需要语音合成、转写能力的团队也值得跟进。

直达链接　https://github.com/ggml-org/llama.cpp/releases/tag/v0.9.0

本期仅一条候选达到提醒阈值；摘要中未披露具体性能数字，相关对比以官方后续 benchmark 为准。