重大 AI 更新提醒

11-05 | llama.cpp 修复 GPU 层卸载计数，避免大模型因 NextN 空层误判而少卸载一层

本期导读

本期聚焦 llama.cpp 的一个关键修复：在自动决定 GPU 卸载层数（fit）时，此前未把不承载权重的 NextN 层计入 n_gpu_layers，导致本应全部卸载的模型仍有一层留在 CPU，出现 offloaded 65/66 layers 这类性能损失。该修复让 fit 的测量结果与模型加载器的实际计数对齐，对多 GPU 部署大模型尤其重要。

已检查来源

GitHub Release: ggml-org/llama.cpp b12136

1. llama.cpp b12136 修复 fit 对 NextN 空层的 GPU 卸载计数，避免大模型少卸载一层

来源 GitHub Release | 类型 GitHub Release | 主题 检索增强与向量模型 时间 11-05 15:32 | 分数 7

是什么

这是 ggml-org/llama.cpp 的 b12136 版本发布，核心变更在 fit 功能：在设置 n_gpu_layers 时，把被跳过的 NextN 层也计入卸载层数，并同步调整持有输出层设备的 tensor split。此前在没有 MTP 的情况下，fit 按 n_layer + 1 计数，而模型加载器按 n_layer_all + 1 计数，后者包含不承载权重的 NextN 层，导致 fit 认为全部卸载后仍有一层留在 CPU，例如 Qwen3.8-27B 在两块 GPU 上显示 offloaded 65/66 layers 。该提交还修复了 31531，并把 hp_ngl_skip 按引用传递、加入 common_get_device_memory_data。

通俗解释

可以把 llama.cpp 的 fit 想成搬家前先量家具尺寸的师傅：它先估算每块 GPU 能放下多少层模型，再告诉加载器往每块卡上放几层。模型里有一些 空箱子 层（NextN 层），里面没有实际权重，但加载器数层数时会把它们算进去。以前 fit 量尺寸时没算这些空箱子，导致它说 全放得下 ，加载器却因为总数对不上，把第一层留在了 CPU 上。结果就是两块 GPU 明明还有空间，模型却有一层跑在慢速 CPU 上，推理变慢。这次修复让 fit 和加载器用同一套数法，空箱子也算进卸载数量，于是该上 GPU 的层都能上去。

主要作用

解决自动 GPU 层卸载时 fit 与加载器计数不一致的问题，避免大模型在多 GPU 环境下因 NextN 空层被漏算而少卸载一层、把部分计算留在 CPU 上，从而恢复预期的 GPU 利用率和推理速度。对于依赖 fit 自动分配显存的部署场景，这是一次直接影响性能正确性的修复。

核心功能

第一，fit 在设置 n_gpu_layers 时把跳过的 NextN 层计入总数，使卸载决策与加载器计数一致；第二，同步调整持有输出层设备的 tensor split，保证层分配落在 fit 实际测量的设备上；第三，hp_ngl_skip 改为按引用传递，并加入 common_get_device_memory_data，便于显存数据计算时使用该参数；第四，修复 31531 所报告的具体症状，即全部卸载后 layer 0 仍留在 CPU。

对比判断

候选摘要中明确给出的对比是修复前后的层卸载计数：修复前 Qwen3.8-27B 在两块 GPU 上显示 offloaded 65/66 layers ，修复后按 fit 测量结果应卸载全部可卸载层；摘要未提供吞吐、延迟或显存占用的具体 benchmark 数字，暂无可信公开对比数据。

适合谁

适合使用 llama.cpp 在多 GPU 或显存受限环境部署大语言模型的开发者与运维团队，尤其是依赖 fit 自动决定 n_gpu_layers 的用户；也适合关注 GGML 后端层分配逻辑、需要排查 明明有显存却有一层在 CPU 问题的研究者与贡献者。

直达链接 https://github.com/ggml-org/llama.cpp/releases/tag/b12136

本期仅一条候选，聚焦 llama.cpp 层卸载计数修复；未包含未经候选证实的速度或显存数据。