重大 AI 更新提醒

11-11 | llama.cpp 连续发布 CUDA BF16 小批量推理优化与测试 API 收敛两项更新

本期导读

本期聚焦 llama.cpp 在同一天内的两个官方 release：b12287 针对 CUDA 后端在 BF16 矩阵行数少、batch size 小的场景引入 MMVF 路径，直接关系到本地推理的 GPU 利用率；b12289 则把测试代码收敛到公开的 ggml API，属于框架工程质量改进。两条更新分别对应推理性能与开发者生态，适合关注本地部署与 ggml 生态的团队跟进。

已检查来源

GitHub Release: ggml-org/llama.cpp b12287、GitHub Release: ggml-org/llama.cpp b12289

1. llama.cpp b12287：CUDA 后端对少行 BF16 矩阵在小 batch 下改用 MMVF

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 时间 11-11 12:15 | 分数 8

是什么

这是 ggml-org/llama.cpp 的官方 release b12287，核心变更在 CUDA 后端：当 BF16 矩阵的行数很少、且 batch size 处于 2 到 8 的小批量区间时，改用 MMVF 内核而不是原来的 MMF。候选摘要给出的典型例子是 qwen4exp 的 hyper-connection 投影，形状为 320 行、K=10240。MMF 每个 block 处理 32 行，这种少行矩阵只能填满少数几个 block，大部分 SM 处于空闲；MMVF 则每个 block 处理一行，在 K 足够长时反而更快。

通俗解释

可以把 GPU 想象成一条有很多工位的流水线。原来的 MMF 方案一次把 32 行数据捆成一包交给一个工位，但有些矩阵只有 320 行，捆完只有 10 包，绝大多数工位闲着。MMVF 改成一行一包，工位立刻被填满，只要每行的计算量（K 很长）足够大，摊薄调度开销后就更快。代价是 MMVF 的开销随行数 batch 增长，所以只在行数 ne11 256 不超过 1024 时启用，并且预算随 SM 数量缩放，像 A16 这种 SM 很少的 GPU 继续走 MMF。

主要作用

解决小 batch 推理时少行 BF16 矩阵导致 GPU SM 利用率低的问题。本地部署大模型、尤其是带 hyper-connection 类投影结构的模型时，batch size 2 到 8 是常见场景，这项改动直接减少空转、提升吞吐，值得关注推理性能的开发者查看。

核心功能

1）按行数、batch 与 K 长度动态选择 MMVF 或 MMF，阈值条件为 rows ne11 256 1024；2）预算随 SM 数量缩放，SM 较少的 GPU（如 A16）保留 MMF 路径；3）按 GPU 架构区分能力上限，Blackwell 支持最多 8 列、max_k=6144，较老 GPU 为 5 列、max_k=4096；4）新增 128x2560、512x2560、320x10240 三组形状在 n=2、3、4、5、8 下的评测用例。

对比判断

候选摘要明确给出的是内核选择层面的对比：MMF 每 block 32 行，少行矩阵下只跑少数 block、多数 SM 空闲；MMVF 每 block 一行，在 K 足够长时胜出，但其成本随 rows batch 增长，而 MMF 在该区间大致持平。摘要未给出端到端吞吐或延迟数字，暂无可信公开对比数据。

适合谁

适合在本地或私有环境用 CUDA GPU 跑 llama.cpp 的开发者、做小 batch 在线推理的服务团队，以及维护 ggml CUDA 内核、关心 SM 利用率与内核调度策略的底层工程师。

直达链接 https://github.com/ggml-org/llama.cpp/releases/tag/b12287

2. llama.cpp b12289：测试代码改为只使用公开的 ggml API

来源　GitHub Release | 类型　GitHub Release | 主题　智能体与开发者平台　时间　11-11 13:03 | 分数　7

是什么	这是 ggml-org/llama.cpp 的官方 release b12289，核心变更是把测试代码改为只依赖公开的 ggml API（PR #32077），不再触碰内部实现细节。release 同时附带 macOS Apple Silicon、macOS Intel、iOS XCFramework、Ubuntu x64/arm64、Ubuntu 24.04 s390x 等平台的预编译产物。它属于框架工程质量与接口边界治理，而不是模型能力或推理速度的变化。
通俗解释	打个比方：一个库的内部函数就像公司内部流程，测试如果直接调用内部流程，公司一改流程测试就全挂。这次改动要求测试只走　对外窗口　，也就是公开 API。这样 ggml 内部怎么重构，测试都只验证对外承诺的行为，既减少误报，也让外部开发者照着测试学到的用法就是官方支持的用法。
主要作用	降低测试对内部实现的耦合，让 ggml 内部重构时测试更稳定，同时保证测试覆盖的是对外承诺的接口行为。对基于 ggml 做二次开发或自行编译 llama.cpp 的团队来说，这意味着公开 API 的边界更清晰，升级时踩坑更少。
核心功能	1）测试代码统一收敛到公开 ggml API，移除对内部符号与实现的依赖；2）覆盖多平台预编译产物，包括 macOS arm64/x64、iOS XCFramework、Ubuntu x64/arm64 与 s390x；3）作为官方 release 发布，便于直接下载对应平台二进制验证。
对比判断	候选摘要未包含任何 benchmark、速度或成本对比，暂无可信公开对比数据。
适合谁	适合维护 ggml/llama.cpp 测试与 CI 的贡献者、基于 ggml 公开 API 做上层封装的框架开发者，以及需要自行编译并在多平台（含 s390x 等非主流架构）部署 llama.cpp 的工程团队。
直达链接	https://github.com/ggml-org/llama.cpp/releases/tag/b12289

以上内容均基于候选中的 llama.cpp 官方 release 摘要整理，未补充摘要之外的性能数字；具体收益请以本地实测为准。