重大 AI 更新提醒

11-13 | transformers 接入 594B 多模态 MoE 新模型，llama.cpp 发布 v1.0.0 并优化投机解码与语法匹配

本期导读

本期聚焦三条高可信官方更新：Hugging Face transformers v5.23.0 新增 Thinking Machines Lab 的 Inkling2 多模态模型支持；llama.cpp 发布 v1.0.0，移除废弃 API、提升投机解码 API 并新增 FP8 KV 缓存等能力；同日 llama.cpp 还优化了语法匹配与投机解码参数行为。这些更新直接影响本地推理、多模态部署与开发者工具链。

已检查来源

GitHub Release: huggingface/transformers v5.23.0、GitHub Release: ggml-org/llama.cpp v1.0.0、GitHub Release: ggml-org/llama.cpp b12364、GitHub Release: ggml-org/llama.cpp b12362、NVIDIA Developer Blog: Serving GLM-5.3 Across Two DGX Stations with vLLM、GitHub Release: langchain-openai 1.8.0

1. transformers v5.23.0 新增 Inkling2 多模态模型支持：594B 总参数、17B 激活的 MoE 架构

来源　GitHub Release | 类型　GitHub Release | 主题　多模态理解　时间　11-13 08:10 | 分数　8

是什么

Hugging Face transformers 发布 v5.23.0，新增对 Thinking Machines Lab 的 Inkling2（Inkling 2 Small）多模态模型的支持。该模型接受文本和图像输入并生成文本输出，语言主干包含 48 层混合专家（MoE）解码器，每层将 token 路由到 384 个专家中的 8 个，总参数 594B、激活参数 17B。它保留 Inkling 解码器结构（学习式相对注意力、短因果卷积、MoE 层），并加入块注意力残差、带学习 sink 的门控注意力与动态 key/value 卷积。图像由基于 Perception Encoder 的视觉 Transformer 编码，按每 40x40 像素块投影为语言模型嵌入。

通俗解释

可以把 Inkling2 想象成一个超大的专家团队：虽然团队总共有 594 名专家，但每处理一个词只叫其中 17 名左右来干活，所以实际计算量远小于总人数。它既能读文字也能看图，比如你给它一张商品图和一句　这个适合送礼吗　，它能结合图片内容和文字问题生成回答。transformers 库这次就是让开发者能直接用几行代码加载并调用这个模型，而不必自己从头实现复杂的模型结构。

主要作用

解决前沿多模态大模型在主流开源框架中缺乏原生支持的问题，让研究者和开发者能在 transformers 生态内直接加载、微调和推理 Inkling2，降低多模态 MoE 模型的使用门槛。

核心功能

1）支持文本　图像输入、文本输出的多模态推理；2）48 层 MoE 解码器，384 专家中每 token 激活 8 个，总参数 594B、激活 17B；3）引入块注意力残差、带学习 sink 的门控注意力、动态 key/value 卷积；4）视觉侧使用 Perception Encoder 的 ViT，按 40x40 像素块投影到语言模型嵌入空间。

对比判断

候选摘要未提供与其他模型的 benchmark、速度或成本对比数据，暂无可信公开对比数据。

适合谁

适合需要部署或研究前沿多模态 MoE 模型的研究团队、希望基于 transformers 做多模态微调的开发者，以及关注 Thinking Machines Lab 模型架构的 AI 工程师。

直达链接　https://github.com/huggingface/transformers/releases/tag/v5.23.0

2. llama.cpp 发布 v1.0.0：移除废弃 API、升级投机解码接口、新增 FP8 KV 缓存与 MoE 专家缓存

来源　GitHub Release | 类型　GitHub Release | 主题　智能体与开发者平台　时间　11-13 04:20 | 分数　7

是什么	llama.cpp 发布 v1.0.0 正式版，移除已废弃的公共 API，并将 NextN/投机解码 API 提升到 llama.h 中。新版本增加 OCP FP8 KV 缓存、带可配置 CPU 份额的主机内存 MoE 专家缓存，以及外部 PLE 分片加载。它新增三种文本架构（Kimi-K3.1-Pro、Ripple、xing4_0）、drama-3 TTS、MageVL-Cowork 与 Kimi-K3.1 视觉支持；加固 llama-server 的 SSRF、CORS、DNS 重绑定与 MCP 工具取消，新增 v1/audio/speech 端点，并更新 ggml 至 v1.0.0。
通俗解释	llama.cpp 是一个让普通电脑也能跑大模型的推理引擎。v1.0.0 像一次大扫除加装修：把多年不用的旧接口清掉，把投机解码（先用小模型草拟、大模型再校验的加速技巧）变成正式接口；同时让 KV 缓存可以用 FP8 压缩，省显存；MoE 专家缓存可以把不常用的专家放到主机内存，按比例分配 CPU 份额。比如你在单张消费级显卡上跑 MoE 模型，以前可能显存不够，现在可以把部分专家放内存里继续跑。
主要作用	解决本地推理引擎长期积累的 API 债务、显存瓶颈与 MoE 模型部署困难，同时提升 llama-server 的安全性与多模态、语音能力，让开发者用更稳定的接口做本地部署。
核心功能	1）移除 35 个废弃函数与 defrag_thold，NextN 投机解码 API 进入 llama.h；2）OCP FP8 KV 缓存与可配置 CPU 份额的主机内存 MoE 专家缓存；3）新增 Kimi-K3.1-Pro、Ripple、xing4_0 文本架构及 drama-3 TTS、MageVL-Cowork、Kimi-K3.1 视觉；4）llama-server 安全加固并新增 v1/audio/speech 端点与新版 Web UI。
对比判断	候选摘要未给出与旧版本或其他推理引擎的 benchmark、速度或成本对比数据，暂无可信公开对比数据。
适合谁	适合在本地或边缘设备部署大模型的开发者、需要 MoE 与多模态推理的工程团队，以及依赖 llama-server 构建服务的后端工程师。

直达链接　https://github.com/ggml-org/llama.cpp/releases/tag/v1.0.0

3. llama.cpp b12364 调整投机解码 p_min 行为：概率采样草稿时改为警告而非静默裁剪

来源　GitHub Release | 类型　GitHub Release | 主题　开发者生态与数据工具　时间　11-13 12:52 | 分数　7

是什么	llama.cpp 发布 b12364，调整投机解码中　　spec-draft-p-min 参数的行为。在拒绝采样下，某位置的接受概率是 1 - TV(p, q)，草稿模型的最高概率并不能反映目标模型会接受多少草稿 token，因此 p_min 截断会丢掉目标模型本可接受的草稿 token。该版本在 MTP 或 DFlash2 采样草稿时跳过 p_min，而 draft-simple 保留该参数；最终改为在所有草稿器和采样模式下恢复 p_min 原有行为，仅在　　spec-draft-p-min　　0 与　　spec-draft-sampling probabilistic 同用时记录警告，建议将 p_min 设为 0。
通俗解释	投机解码就像让一个打字快的小助手先草拟句子，再由大模型审核。p_min 原本是　小助手没把握的草稿直接扔掉　的阈值，但审核通过率并不等于小助手的自信度，所以这个阈值可能误扔好草稿。新版本不再偷偷扔掉，而是在你同时开启概率采样和 p_min 时提醒你：这个组合可能不划算，建议把 p_min 设为 0。这样开发者能更清楚地知道参数的实际效果，而不是被静默行为误导。
主要作用	解决投机解码中 p_min 参数在概率采样草稿场景下语义不准确、可能丢弃可接受 token 的问题，通过警告机制让开发者理解参数行为并做出更合理的配置。
核心功能	1）在 MTP 与 DFlash2 采样草稿时跳过 p_min 截断；2）draft-simple 保留 p_min，因为每个额外草稿 token 都需完整草稿模型前向；3）最终恢复所有草稿器与采样模式下的 p_min 原有行为；4）当　p_min　　0 与 probabilistic 采样同用时输出警告并建议 p_min 设为 0。
对比判断	候选摘要未提供与旧版本或其他投机解码实现的 benchmark、速度或成本对比数据，暂无可信公开对比数据。
适合谁	适合使用 llama.cpp 投机解码做低延迟推理的开发者、调优本地推理性能的工程师，以及研究拒绝采样与草稿模型策略的研究者。

直达链接　https://github.com/ggml-org/llama.cpp/releases/tag/b12364

本期仅收录候选源中可核实的官方发布与 GitHub Release；未提供的 benchmark、价格与速度数据一律不编造。