重大 AI 更新提醒

11-14 | llama.cpp 修复 Qwen2-VL 量化推理崩溃

本期导读

本期聚焦 llama.cpp 针对 Qwen2-VL 模型在 NVFP4 量化下推理输出乱码或 NaN 的严重缺陷修复。该问题会导致模型完全不可用，修复后恢复了量化推理的正确性，对本地部署多模态模型的开发者尤为关键。

已检查来源

GitHub Release

1. llama.cpp b12385 修复 Qwen2-VL 的 FFN 权重缩放未应用问题

来源 GitHub Release | 类型 GitHub Release | 主题 推理性能与基础设施 时间 11-14 12:48 | 分数 7

是什么

这是 ggml-org/llama.cpp 项目的一个 GitHub Release（b12385），核心变更是在 qwen2vl 计算图中正确传递 FFN 的 ffn_up、gate、down 三组权重缩放（scales）。此前 qwen2vl 图在构建 FFN 时对这些缩放传入了 NULL，导致通用流程加载的 per-tensor NVFP4 量化缩放从未被应用，模型输出完全错误。

通俗解释

可以把量化模型想象成一本被压缩过的说明书：每个章节的数值都按一个 缩放系数 压缩存储，阅读时必须乘回这个系数才能还原原意。Qwen2-VL 的 FFN 部分有三个关键章节（ffn_up、gate、down），但 llama.cpp 在读取时忘了把对应的缩放系数传进去，相当于用错误的比例去还原，结果整本书读出来全是乱码。修复方式就是像 qwen2 那样，把这三个系数正确传给 build_ffn，让还原过程恢复正常。

主要作用

解决 Qwen2-VL 在 NVFP4 量化下推理结果完全不可用的问题。根据 release 说明，该缺陷会导致 CUDA 上困惑度（PPL）飙到约 1e6、CPU 上直接出现 NaN，模型输出垃圾。修复后量化推理恢复正确，避免开发者在本地部署多模态模型时遇到难以定位的静默错误。

核心功能

1) 在 qwen2vl 图中将 ffn_up/gate/down 的 per-tensor NVFP4 scales 正确传入 build_ffn；2) 对齐 qwen2 的已有实现，保持不同模型架构间缩放处理的一致性；3) 修复了因缩放缺失导致的 CUDA PPL 异常与 CPU NaN 问题；4) 随 release 提供 macOS（arm64/x64）、iOS XCFramework、Ubuntu x64 等多平台预编译包。

对比判断

候选摘要中明确给出修复前后的对比：修复前 CUDA 上 PPL 约 1e6、CPU 上为 NaN；修复后恢复正确推理。未提供与其他推理框架的速度或成本对比数据。

适合谁

适合在本地或边缘设备上使用 llama.cpp 部署 Qwen2-VL 多模态模型的开发者、做量化推理研究的研究者，以及依赖 NVFP4 低比特量化在 CUDA/CPU 上跑视觉语言模型的工程团队。

直达链接 https://github.com/ggml-org/llama.cpp/releases/tag/b12385

本期仅一条候选，聚焦 llama.cpp 量化推理正确性修复；建议使用 Qwen2-VL + NVFP4 的团队尽快升级到 b12385。