

# 每日科技快报

05-22 | 轻量版 | 官方发布、GitHub Release、论文与开发者生态优先

## 本期导读

本期按高可信来源、影响范围、可验证性和新颖性筛选。没有可靠 benchmark 的条目会明确标注暂无可信公开对比数据。

## 已检查来源类别

Google Developers Blog、arXiv cs.AI、arXiv cs.CL、arXiv cs.CV、arXiv stat.ML

### 1. Cambrian-P: Pose-Grounded Video Understanding

是什么: arXiv cs.CV 发布或更新的内容。Camera pose matters. The position and orientation of each viewpoint define a shared spatial coordinate frame that relates observations across video frames. Yet this signal is largely absent from multimodal LLMs (MLLMs) for video understanding, which process frames as isolated 2D snapshots, instead of the persistent scene humans perceive. We revisit pose as a

主要作用: 帮助开发者、数据科学或 AI 工程团队判断是否值得进一步阅读、试用或纳入技术储备。

核心功能: 请以原始链接中的官方说明、release note、模型卡或论文摘要为准; 本快报只做低成本初筛。

对比: 若原始来源没有明确 benchmark、价格或性能数据, 则暂无可信公开对比数据。

适合谁: 适合关注 AI 工具、数据科学、机器学习平台、开发者基础设施和开源生态的人。

直达链接: <https://arxiv.org/abs/2605.22819v1>

### 2. DeltaBox: Scaling Stateful AI Agents with Millisecond-Level Sandbox Checkpoint/Rollback

是什么: arXiv cs.AI 发布或更新的内容。LLM-powered AI agents require high-frequency state exploration (e.g., test-time tree search and reinforcement learning), relying on rapid checkpoint and rollback (C/R) of the complete sandbox state, including files and process state (e.g., memory, contexts, etc.). Existing mechanisms duplicate the entire state, causing hundreds of milliseconds to seconds of

主要作用: 帮助开发者、数据科学或 AI 工程团队判断是否值得进一步阅读、试用或纳入技术储备。

核心功能: 请以原始链接中的官方说明、release note、模型卡或论文摘要为准; 本快报只做低成本初筛。

对比: 若原始来源没有明确 benchmark、价格或性能数据, 则暂无可信公开对比数据。

适合谁: 适合关注 AI 工具、数据科学、机器学习平台、开发者基础设施和开源生态的人。

直达链接: <https://arxiv.org/abs/2605.22781v1>

### 3. WorldKV: Efficient World Memory with World Retrieval and Compression

是什么: arXiv cs.CV 发布或更新的内容。Autoregressive video diffusion models have enabled real-time, action-conditioned world generation. However, sustaining a persistent world, where revisiting a previously seen viewpoint yields consistent content, remains an open problem. Full KV-cache attention preserves this consistency but breaks real-time constraints: memory footprint and attention cost gro

主要作用: 帮助开发者、数据科学或 AI 工程团队判断是否值得进一步阅读、试用或纳入技术储备。

核心功能: 请以原始链接中的官方说明、release note、模型卡或论文摘要为准; 本快报只做低成本初筛。

对比: 若原始来源没有明确 benchmark、价格或性能数据, 则暂无可信公开对比数据。

适合谁: 适合关注 AI 工具、数据科学、机器学习平台、开发者基础设施和开源生态的人。

直达链接: <https://arxiv.org/abs/2605.22718v1>

### 4. Agentic CLEAR: Automating Multi-Level Evaluation of LLM Agents

是什么: arXiv cs.CL 发布或更新的内容。Agentic systems are becoming more capable: agents define strategies, take actions, and interact with different environments. This autonomy poses serious challenges for overseeing and assessing agent behavior. Most current tools are limited, focusing on observability with basic evaluation capabilities or imposing static, hand-crafted error taxonomies that can

主要作用: 帮助开发者、数据科学或 AI 工程团队判断是否值得进一步阅读、试用或纳入技术储备。

核心功能: 请以原始链接中的官方说明、release note、模型卡或论文摘要为准；本快报只做低成本初筛。

对比: 若原始来源没有明确 benchmark、价格或性能数据，则暂无可信公开对比数据。

适合谁: 适合关注 AI 工具、数据科学、机器学习平台、开发者基础设施和开源生态的人。

直达链接: <https://arxiv.org/abs/2605.22608v1>

## 5. Guiding Multi-Objective Genetic Programming with Description Length Improves Symbolic Regression Solutions

是什么: arXiv stat.ML 发布或更新的内容。Symbolic regression with genetic programming (GPSR) may suffer from overfitting and structural bloat, especially when noise is present. In this paper we evaluate description length (DL) and fractional Bayes factor (FBF) criteria as principled, data-efficient alternatives to heuristics for selecting compact expressions that generalise well. We implement DL us

主要作用: 帮助开发者、数据科学或 AI 工程团队判断是否值得进一步阅读、试用或纳入技术储备。

核心功能: 请以原始链接中的官方说明、release note、模型卡或论文摘要为准；本快报只做低成本初筛。

对比: 若原始来源没有明确 benchmark、价格或性能数据，则暂无可信公开对比数据。

适合谁: 适合关注 AI 工具、数据科学、机器学习平台、开发者基础设施和开源生态的人。

直达链接: <https://arxiv.org/abs/2605.22374v1>

## 6. Google Tensor SDK Beta with LiteRT

是什么: Google Developers Blog 发布或更新的内容。The Google Tensor ML SDK is graduating to its Beta phase, allowing developers to build and deploy high-performance machine learning models directly onto the TPU of Google Pixel 10 devices. By integrating with LiteRT, Google's edge deployment framework, the SDK provides a unified workflow for developers to convert, compile, and run PyTorch or TFLite models wi

主要作用: 帮助开发者、数据科学或 AI 工程团队判断是否值得进一步阅读、试用或纳入技术储备。

核心功能: 请以原始链接中的官方说明、release note、模型卡或论文摘要为准；本快报只做低成本初筛。

对比: 若原始来源没有明确 benchmark、价格或性能数据，则暂无可信公开对比数据。

适合谁: 适合关注 AI 工具、数据科学、机器学习平台、开发者基础设施和开源生态的人。

直达链接: <https://developers.googleblog.com/google-tensor-sdk-beta-with-litert/>

## 7. Blazing fast on-device GenAI with LiteRT-LM

是什么: Google Developers Blog 发布或更新的内容。Google AI Edge' s LiteRT-LM provides a production-proven, highly optimized infrastructure for running Gemma 4 across cross-platform mobile and edge environments. It actively unlocks the model's native multimodal and agentic features on-device by utilizing memory-efficient dynamic loading, Multi-Token Prediction for up to a 2.2x speedup, and advanced orchestra

主要作用: 帮助开发者、数据科学或 AI 工程团队判断是否值得进一步阅读、试用或纳入技术储备。

核心功能: 请以原始链接中的官方说明、release note、模型卡或论文摘要为准；本快报只做低成本初筛。

对比: 若原始来源没有明确 benchmark、价格或性能数据，则暂无可信公开对比数据。

适合谁: 适合关注 AI 工具、数据科学、机器学习平台、开发者基础设施和开源生态的人。

直达链接: <https://developers.googleblog.com/blazing-fast-on-device-genai-with-litert-lm/>

## 8. Speeding Up AI: Bringing Google Colossus to PyTorch via GCSFS and Rapid Bucket

是什么: Google Developers Blog 发布或更新的内容。Google Cloud has introduced a high-performance integration that connects Rapid Storage directly to PyTorch via the fsspec interface to eliminate AI training bottlenecks. By utilizing Google's Colossus architecture and bidirectional gRPC streaming, the solution offers up to 15 TiB/s aggregate throughput and significant reductions in latency. These improvement

主要作用: 帮助开发者、数据科学或 AI 工程团队判断是否值得进一步阅读、试用或纳入技术储备。

核心功能: 请以原始链接中的官方说明、release note、模型卡或论文摘要为准；本快报只做低成本初筛。

对比: 若原始来源没有明确 benchmark、价格或性能数据，则暂无可信公开对比数据。

适合谁: 适合关注 AI 工具、数据科学、机器学习平台、开发者基础设施和开源生态的人。

直达链接: <https://developers.googleblog.com/speeding-up-ai-bringing-google-colossus-to-pytorch-via-gcsfs-and-rapid-bucket/>

备注: 本 PDF 由 GitHub Actions 自动生成并通过 Telegram 推送。