

每日 AI 简报

05-24 | Google I/O 2026 开发者大会专题：Agent 平台、端侧推理与多模态嵌入全面升级

本期导读

本期聚焦 Google I/O 2026 开发者主题演讲及一系列重磅发布，涵盖从独立 Agent 开发框架、端侧 NPU 推理加速到多模态嵌入模型 GA 等关键更新。同时，MLflow 3.13.0rc0 强化了 Agent 可观测性与权限管理，为生产级 AI 应用提供更坚实的基础。

已检查来源

Google Developers Blog、GitHub Release

1. All the news from the Google I/O 2026 Developer keynote

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-24 13:45 | 分数 6

是什么 Google I/O 2026 开发者主题演讲的完整新闻汇总，宣布从辅助 AI 向独立 Agent 的转变，发布 Gemini 3.5 系列、Antigravity Agent 开发平台、Android Bench 评估排行榜、WebMCP 开放标准等。

通俗解释 想象一下，以前 AI 只能帮你查天气、设闹钟，现在 Google 想让 AI 变成能独立完成复杂任务的“数字员工”。比如，你告诉它“帮我订一张下周去北京的机票，并安排好酒店和会议”，它就能自己调用多个工具、协调步骤，最终完成任务。这次发布的新平台和工具就是让开发者更容易构建这样的“数字员工”。

主要作用 汇总 Google I/O 2026 所有关键发布，帮助开发者快速了解 AI 平台的最新方向：从辅助 AI 转向独立 Agent，以及移动、Web 开发工具的全面升级。

核心功能 Gemini 3.5 系列模型发布；Antigravity Agent 开发平台；Android Bench 评估排行榜与自动化迁移 Agent；WebMCP 开放标准使浏览器 Agent 能执行复杂任务

对比判断 暂无可信公开对比数据

适合谁 所有关注 Google AI 生态的开发者、产品经理和技术决策者。

直达链接 <https://developers.googleblog.com/all-the-news-from-the-google-io-2026-developer-keynote/>

2. A2UI v0.9: The New Standard for Portable, Framework-Agnostic Generative UI

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-24 13:45 | 分数 8

是什么	A2UI v0.9 是一个框架无关的生成式 UI 标准，允许 AI Agent 实时生成符合公司现有设计系统的 UI 组件。
通俗解释	以前，AI 生成的界面往往需要针对不同平台（如 React、Flutter、Angular）分别开发，就像给每个手机型号单独做手机壳。A2UI 定义了一套通用 语言 ，AI 只需描述界面意图，就能自动适配到各种框架，大大减少了重复工作。
主要作用	解决生成式 UI 从实验到生产的关键问题：跨平台兼容性、实时流式渲染和设计系统集成。
核心功能	框架无关：支持 React、Flutter、Angular 等渲染器；低延迟流式传输：实时生成 UI 组件；集成 AG2 和 Vercel 等生态
对比判断	暂无可信公开对比数据
适合谁	前端开发者、AI Agent 构建者、需要动态生成 UI 的产品团队。
直达链接	https://developers.googleblog.com/a2ui-v0-9-generative-ui/

3. Building real-world on-device AI with LiteRT and NPU

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-24 13:45 | 分数 8

是什么	LiteRT 是一个生产级框架，帮助移动开发者利用 NPU（神经网络处理器）运行 AI 模型，克服 CPU/GPU 的性能和功耗限制。
通俗解释	手机上的 AI 应用（如实时视频特效、语音识别）通常很耗电，用 CPU 或 GPU 跑模型就像用普通汽车引擎跑 F1 赛道。NPU 是专门为 AI 设计的 赛车引擎 ，LiteRT 则提供了统一的 驾驶舱 ，让开发者无需关心底层硬件细节，就能轻松调用 NPU 的能力。
主要作用	让移动端 AI 应用更高效、更省电，支持实时视频、动画和语音识别等场景。
核心功能	统一 API 抽象硬件复杂性；跨平台兼容：移动设备、AI PC、工业 IoT；提供基准测试工具
对比判断	暂无可信公开对比数据
适合谁	移动端 AI 开发者、嵌入式系统工程师、需要端侧实时 AI 的应用团队。
直达链接	https://developers.googleblog.com/building-real-world-on-device-ai-with-litert-and-npu/

4. Speeding Up AI: Bringing Google Colossus to PyTorch via GCSFS and Rapid Bucket

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-24 13:45 | 分数 8

是什么	Google Cloud 推出高性能存储集成方案，通过 fsspec 接口将 Rapid Storage 直接连接到 PyTorch，消除 AI 训练瓶颈。
通俗解释	训练大模型时，数据读取常常成为 堵车 的瓶颈 GPU 算得飞快，但数据来不及喂给它。这个方案就像给数据仓库修了一条高速公路，利用 Google 的 Colossus 架构和双向 gRPC 流，实现高达 15 TiB/s 的聚合吞吐量，让训练时间缩短 23%，而且开发者只需改一下存储桶类型，无需改代码。
主要作用	加速 AI 训练，减少数据加载延迟，提升 GPU 利用率。
核心功能	15 TiB/s 聚合吞吐量；零代码变更：仅需更新存储桶类型；基于 Colossus 架构和双向 gRPC 流
对比判断	相比传统方案，总训练时间缩短 23%。
适合谁	PyTorch 开发者、AI 训练工程师、需要优化数据管线的团队。

直达链接 <https://developers.googleblog.com/speeding-up-ai-bringing-google-colossus-to-pytorch-via-gcsfs-and-rapid-bucket/>

5. Blazing fast on-device GenAI with LiteRT-LM

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-24 13:45 | 分数 8

是什么	LiteRT-LM 是 Google AI Edge 提供的生产级推理引擎，专门优化 Gemma 4 模型在移动和边缘设备上的运行。
通俗解释	想在手机上运行一个多模态 AI 模型（比如同时理解图片和文字），通常又慢又占内存。LiteRT-LM 通过 动态加载 （只加载需要的部分）和 多 Token 预测 （一次预测多个词）等技术，让 Gemma 4 在手机上跑得飞快，速度提升最高 2.2 倍。它还支持 思考模式 和 约束解码 ，让 AI 输出更可控。
主要作用	让 Gemma 4 的多模态和 Agent 能力在端侧高效运行，支持跨平台移动和边缘设备。
核心功能	内存高效动态加载；多 Token 预测实现 2.2 倍加速；支持思考模式和约束解码；新增 Swift API 和 WebGPU JavaScript API
对比判断	暂无可信公开对比数据
适合谁	移动端 AI 开发者、边缘计算工程师、需要端侧运行 Gemma 4 的团队。

直达链接 <https://developers.googleblog.com/blazing-fast-on-device-genai-with-litert-lm/>

6. Building with Gemini Embedding 2: Agentic multimodal RAG and beyond

来源 Google Developers Blog | 类型 官方发布 | 主题 智能体与开发者平台 | 时间 05-24 13:45 | 分数 7

是什么	Gemini Embedding 2 正式版发布，是一个统一的多模态嵌入模型，能将文本、图像、视频、音频和文档映射到同一语义空间。
通俗解释	以前，搜索图片和搜索文字用的是不同的 语言 ，无法直接比较。Gemini Embedding 2 就像一个万能翻译器，把图片、视频、音频、文档都翻译成同一种 语义语言 ，这样你就可以用文字搜图片，或者用图片搜视频。比如，上传一张产品照片，就能找到相关的说明书视频。
主要作用	为 Agent 式 RAG、视觉搜索、内容审核等任务提供统一的多模态语义基础。
核心功能	支持文本、图像、视频、音频、文档混合输入；覆盖 100 多种语言；任务特定前缀和 Matryoshka 维度缩减
对比判断	暂无可信公开对比数据
适合谁	构建多模态搜索、RAG 系统、内容审核的开发者。

直达链接 <https://developers.googleblog.com/building-with-gemini-embedding-2/>

7. mlflow/mlflow release v3.13.0rc0: We're excited to announce MLflow 3.13.0rc0, which deepens agent observability, tightens permissions, and broadens deployment options

来源 GitHub Release | 类型 GitHub Release | 主题 智能体与开发者平台 | 时间 05-22 02:41 | 分数 8

是什么	MLflow 3.13.0rc0 发布，主要增强 Agent 可观测性、权限控制和部署选项。
通俗解释	MLflow 是管理机器学习实验和模型生命周期的工具。新版本像给这个工具加了一套 监控摄像头 和 门禁系统 ：你可以更清楚地看到 Agent 的运行情况（可观测性），精细控制谁可以访问哪些资源（RBAC 权限），并且支持更多部署方式。比如，管理员可以设置只有特定团队能部署模型，并查看每个 Agent 的调用日志。
主要作用	提升 MLflow 在生产环境中的安全性和可管理性，特别是针对 Agent 工作流。
核心功能	RBAC 权限大修：统一权限 API，新增 Admin UI；Coding-Agent 追踪插件：支持 Claude Code、OpenClaw 等；Prompt 成为一等 RBAC 资源类型
对比判断	暂无可信公开对比数据
适合谁	MLOps 工程师、数据科学家、需要管理 ML 实验和 Agent 的团队。

直达链接 <https://github.com/mlflow/mlflow/releases/tag/v3.13.0rc0>

8. Supercharging LLM inference on Google TPUs: Achieving 3X speedups with diffusion-style speculative decoding

来源 Google Developers Blog | 类型 官方发布 主题 检索增强与向量模型 时间 05-24 13:45 | 分数 6

是什么	UCSD 研究人员在 Google TPU 上实现了 DFlash，一种块扩散推测解码方法，将 LLM 推理速度提升约 3 倍。
通俗解释	大模型生成文本时，通常是一个词一个词地挤出来，很慢。DFlash 像批量印刷一样，一次生成一整块候选词，然后快速验证。这就像从手写一封信变成用印刷机一次印一页，速度自然快很多。在 TPU 上，这种方法达到了平均 3.13 倍加速，峰值性能接近 EAGLE-3 的两倍。
主要作用	突破传统自回归解码的串行瓶颈，显著加速 LLM 推理。
核心功能	块扩散推测解码：一次生成多个候选 Token；集成 vLLM 生态；利用 TPU 的并行验证能力
对比判断	平均加速 3.13x，峰值性能接近 EAGLE-3 的两倍。
适合谁	LLM 推理优化研究者、TPU 用户、需要低延迟推理的开发者。

直达链接 <https://developers.googleblog.com/supercharging-llm-inference-on-google-tpus-achieving-3x-speedups-with-diffusion-style-speculative-decoding/>

本期简报基于 Google I/O 2026 期间发布的多项更新，涵盖 Agent 平台、端侧推理、存储优化、嵌入模型及 MLflow 新版本。所有信息均来自候选源，未做任何编造。