

每日 AI 简报

05-25 | Google I/O 2026 开发者大会专题：Agent、端侧推理与多模态嵌入全面升级

本期导读

本期聚焦 Google I/O 2026 开发者大会发布的一系列 AI 基础设施更新，涵盖生成式 UI 标准 A2UI v0.9、端侧推理框架 LiteRT 系列、多模态嵌入模型 Gemini Embedding 2 以及 TPU 推理加速技术。这些发布标志着 AI 从辅助工具向独立智能体的转变，并提供了从云端到边缘的全栈开发工具。

已检查来源

Google Developers Blog

1. A2UI v0.9: The New Standard for Portable, Framework-Agnostic Generative UI

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-25 14:09 | 分数 8

是什么 A2UI v0.9 是一个框架无关的生成式 UI 标准，允许 AI 智能体实时生成符合公司现有设计系统的 UI 组件。

通俗解释 想象一下，你让 AI 助手帮你做一个购物车页面，它不仅能理解你的需求，还能自动生成一个符合你公司设计规范的、可交互的界面，而且这个界面可以在 React、Flutter 或 Angular 等不同框架下运行。A2UI 就是实现这种能力的底层标准，它把 UI 的意图（比如 显示一个按钮）和具体实现（按钮用什么颜色、多大）分离开，让 AI 专注于生成内容，而开发者可以自由选择前端框架。

主要作用 解决生成式 UI 从实验性演示到生产级应用的关键问题：如何让 AI 生成的 UI 组件可移植、低延迟、且与现有设计系统兼容。

核心功能 框架无关：支持 React、Flutter、Angular 等主流渲染器；低延迟流式传输：通过解耦 UI 意图与平台，实现实时生成；集成 AG2 和 Vercel 等生态，便于部署

对比判断 暂无可信公开对比数据

适合谁 前端开发者、AI 应用开发者、设计系统维护团队，特别是需要构建动态 UI 的智能体应用团队。

直达链接 <https://developers.googleblog.com/a2ui-v0-9-generative-ui/>

2. Building real-world on-device AI with LiteRT and NPU

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-25 14:09 | 分数 8

是什么	LiteRT 是一个生产级框架，帮助移动开发者利用神经处理单元（NPU）运行 AI 模型，克服 CPU/GPU 的性能和功耗限制。
通俗解释	手机上的 AI 应用（比如实时视频特效、语音识别）通常很耗电，而且容易发热。LiteRT 提供了一个统一的 API，让开发者不用关心底层硬件是哪个厂商的 NPU，就能高效地运行模型。就像你写代码时不用管屏幕是 LCD 还是 OLED，系统会自动适配。Google Meet 和 Epic Games 已经用它实现了实时视频处理和动画渲染。
主要作用	解决端侧 AI 部署中性能与功耗的平衡问题，让复杂的 AI 模型能在手机、AI PC 和 IoT 设备上流畅运行。
核心功能	统一 API 抽象硬件复杂性；提供基准测试工具；跨平台兼容：移动设备、AI PC、工业 IoT
对比判断	相比传统 CPU/GPU 处理，NPU 方案在功耗和实时性上有显著优势，但具体数值未公开。
适合谁	移动应用开发者、嵌入式 AI 工程师、需要部署实时 AI 功能的团队。
直达链接	https://developers.googleblog.com/building-real-world-on-device-ai-with-litert-and-npu/

3. Speeding Up AI: Bringing Google Colossus to PyTorch via GCSFS and Rapid Bucket

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-25 14:09 | 分数 8

是什么	Google Cloud 推出了一项高性能集成，通过 fsspec 接口将 Rapid Storage 直接连接到 PyTorch，消除 AI 训练瓶颈。
通俗解释	训练大型 AI 模型时，数据读取往往成为瓶颈 GPU 算得飞快，但数据从硬盘加载太慢。这个方案利用 Google 的 Colossus 架构和双向 gRPC 流，实现了高达 15 TiB/s 的聚合吞吐量。开发者只需更改存储桶类型，无需修改代码，就能将训练时间缩短 23%。
主要作用	解决 AI 训练中数据加载的 I/O 瓶颈，提升 GPU 利用率，加速模型迭代。
核心功能	15 TiB/s 聚合吞吐量；零代码变更：仅需更新存储桶类型；基于 fsspec 接口，与 PyTorch 原生集成
对比判断	相比传统存储方案，总训练时间缩短 23%，吞吐量提升显著。
适合谁	深度学习工程师、数据科学家、使用 PyTorch 进行大规模训练的团队。
直达链接	https://developers.googleblog.com/speeding-up-ai-bringing-google-colossus-to-pytorch-via-gcsfs-and-rapid-bucket/

4. Blazing fast on-device GenAI with LiteRT-LM

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-25 14:09 | 分数 8

是什么	LiteRT-LM 是 Google AI Edge 提供的生产级推理引擎，专门优化在移动和边缘设备上运行 Gemma 4 模型。
通俗解释	想象一下，你的手机能本地运行一个多模态 AI 模型，不仅能理解文字，还能处理图片和语音，而且响应速度很快。LiteRT-LM 通过内存高效动态加载、多 token 预测（速度提升 2.2 倍）以及思考模式、约束解码等高级功能，让 Gemma 4 的智能体能力在设备端充分发挥。它还新增了 Swift API 和 WebGPU 加速的 JavaScript API，支持苹果生态和浏览器推理。
主要作用	让强大的多模态 AI 模型能在手机、平板等设备上本地运行，保护隐私并降低延迟。
核心功能	多 token 预测实现 2.2 倍加速；支持思考模式和约束解码；新增 Swift API 和 WebGPU JavaScript API
对比判断	暂无可信公开对比数据
适合谁	移动端 AI 开发者、边缘计算工程师、需要离线 AI 能力的应用团队。
直达链接	https://developers.googleblog.com/blazing-fast-on-device-genai-with-litert-lm/

5. Google Tensor SDK Beta with LiteRT

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-25 14:09 | 分数 8

是什么	Google Tensor ML SDK 进入 Beta 阶段，允许开发者在 Pixel 10 的 TPU 上部署机器学习模型，并与 LiteRT 集成。
通俗解释	Pixel 10 手机里有一个专门的 AI 芯片（TPU），以前开发者很难直接利用它。现在 Tensor SDK 提供了统一的工作流，可以把 PyTorch 或 TFLite 模型转换、编译并运行在 TPU 上，如果 TPU 不支持，还能自动回退到 CPU/GPU。SDK 还附带一个模型花园，包含超过 100 个经典和生成式 AI 模型，比如 Gemma 3，可以用来做语音识别、图像识别和文本生成。
主要作用	让开发者轻松利用 Pixel 设备的 TPU 硬件加速，实现低延迟、隐私保护的端侧 AI 功能。
核心功能	统一工作流：转换、编译、运行 PyTorch/TFLite 模型；超过 100 个预训练模型（含 Gemma 3）；自动回退机制，确保兼容性
对比判断	暂无可信公开对比数据
适合谁	Android 开发者、移动端 AI 工程师、希望利用 Pixel 硬件加速的团队。
直达链接	https://developers.googleblog.com/google-tensor-sdk-beta-with-litert/

6. Building with Gemini Embedding 2: Agentic multimodal RAG and beyond

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-25 14:09 | 分数 7

是什么	Gemini Embedding 2 是一个统一的多模态嵌入模型，能将文本、图像、视频、音频和文档映射到同一个语义空间。
通俗解释	以前，如果你想搜索包含 红色汽车 的图片，需要分别处理文字和图片，然后比较它们的向量。Gemini Embedding 2 可以一次性处理多种类型的数据，比如你上传一段视频和一段文字描述，它能理解它们是否相关。这就像给 AI 装了一个 万能翻译器 ，把不同形式的信息变成统一的语言。它支持超过 100 种语言，还提供了任务特定前缀和 Matryoshka 维度缩减功能，让开发者可以灵活调整精度和效率。
主要作用	为智能体 RAG、视觉搜索、内容审核等任务提供统一的多模态语义理解基础。
核心功能	单次请求处理文本、图像、视频、音频、文档；支持 100+ 语言；任务特定前缀和 Matryoshka 维度缩减
对比判断	暂无可信公开对比数据
适合谁	构建 RAG 系统的开发者、多模态搜索团队、内容审核平台。

直达链接 <https://developers.googleblog.com/building-with-gemini-embedding-2/>

7. Supercharging LLM inference on Google TPUs: Achieving 3X speedups with diffusion-style speculative decoding

来源 Google Developers Blog | 类型 官方发布 主题 检索增强与向量模型 时间 05-25 14:09 | 分数 6

是什么	UCSD 研究人员在 Google TPU 上实现了 DFlash，一种块扩散推测解码方法，将 LLM 推理速度提升 3 倍以上。
通俗解释	大语言模型生成文本时，通常是一个词一个词地预测，速度很慢。推测解码的思路是让一个小模型快速生成多个候选词，然后让大模型一次性验证。DFlash 更进一步，它像画画一样，一次 涂抹 出一整块候选词，而不是逐个画。在 TPU 上，这种方法平均加速 3.13 倍，峰值性能接近 EAGLE-3 的两倍。代码已开源并集成到 vLLM 生态。
主要作用	突破 LLM 推理的序列生成瓶颈，显著降低延迟，适用于复杂推理任务。
核心功能	块扩散推测解码，单次前向传播生成整块候选 token；平均 3.13 倍加速，峰值接近 EAGLE-3 两倍；开源集成到 vLLM
对比判断	相比传统自回归解码，平均加速 3.13x；相比 EAGLE-3，峰值性能翻倍。
适合谁	LLM 推理优化工程师、TPU 用户、需要低延迟推理的 AI 应用团队。

直达链接 <https://developers.googleblog.com/supercharging-llm-inference-on-google-tpus-achieving-3x-speedups-with-diffusion-style-speculative-decoding/>

8. Announcing Genkit Middleware: Intercept, extend, and harden your agentic apps

来源 Google Developers Blog | 类型 官方发布 主题 智能体与开发者平台 时间 05-25 14:09 | 分数 6

是什么	Genkit 是一个开源框架，提供中间件系统来拦截、扩展和加固智能体 AI 应用。
通俗解释	构建 AI 智能体时，你经常需要添加一些通用功能，比如重试失败的请求、切换备用模型、或者让用户确认某个操作。Genkit 的中间件就像流水线上的插件，你可以在 AI 生成请求的不同阶段（生成前、模型调用时、工具调用后）插入自定义逻辑。例如，你可以写一个中间件，当模型返回错误时自动重试，或者当智能体要执行敏感操作时暂停并请求人工批准。所有中间件都可以通过专门的开发者 UI 进行调试。
主要作用	简化生产级智能体应用的开发，提供可复用的可靠性、安全性和可观测性能力。
核心功能	支持 TypeScript、Go、Dart、Python；中间件可拦截 generate、model、tool 三层调用；提供开发者 UI 用于调试和监控
对比判断	暂无可信公开对比数据
适合谁	构建智能体应用的开发者、需要高可靠性和人工审核流程的团队。
直达链接	https://developers.googleblog.com/announcing-genkit-middleware-intercept-extend-and-harden-your-agentic-apps/

本期简报基于 Google I/O 2026 期间发布的官方博客，所有信息均来自候选源。